



Università di Catania

Machine Learning

Autori:

Emanuele Galiano
Damiano Trovato

Revisione:

Prof. Giovanni M.
Farinella

Anno Accademico 2025/2026

Dipartimento di Matematica e Informatica

Corso di Laurea Triennale in Informatica (L-31)

Indice

I	Concetti preliminari	ix
II	Teoria, algoritmi e modelli di Machine Learning	1
1	Introduzione al Machine Learning	3
1.1	Prime definizioni di Machine Learning	3
1.1.1	Arthur Samuel - 1959	3
1.1.2	Perchè abbiamo bisogno del Machine Learning	3
1.1.3	Esempio delle email spam e non-spam	4
1.1.4	Tom Mitchel - 1998	4
1.2	Definizioni fondamentali	4
1.2.1	Definizione di Task	4
1.2.2	Definizione di Esperienza	4
1.2.3	Definizione di Performance	5
1.2.4	Esempio completo	5
1.3	Task, Esempi ed Etichette	6
1.4	Features	6
1.4.1	Estrazione	6
1.4.2	Definizione formale	7
1.5	Esempio delle Email Spam e Non Spam	7
1.6	Tipologie di Task	8
1.6.1	Classificazione	8
1.6.2	Regressione	9
1.7	Tipi di Machine Learning	10
1.7.1	Supervised Learning e Unsupervised Learning	10
1.7.2	Reinforcement Learning	11
1.8	Misura di Performance (P)	12
1.8.1	Esempio	12
1.9	Elementi fondamentali del Machine Learning	12
1.9.1	Experience (E)	12
1.9.2	Dataset (D)	13
1.9.3	Design Matrix	13
1.9.4	Esempio	13

1.9.5	Learning	14
1.9.6	Il paradigma Training/Testing	15
1.9.7	Normalizzazione	16
1.10	Iperparametri	17
1.10.1	k-fold Cross Validation	17
1.11	Overfitting e underfitting	17
1.11.1	Bias e Variance	18
2	I primi modelli di Machine Learning	21
2.1	Neurone computazionale - modello di McCulloch-Pitt	21
2.1.1	Limitazioni del modello di McCulloch-Pitt	22
2.2	Percettrone - Rosenblatt	22
2.2.1	Processo generale di training del percettrone	24
2.2.2	Implementazione del training	24
2.2.3	Versione di Adaline	25
2.3	Modelli lineari	25
2.3.1	Problema dello XOR	25
3	Regressione	29
3.1	Ingredienti del task	29
3.1.1	Tipi di regressione	29
3.2	Regressione lineare semplice	30
3.2.1	Funzione di loss	30
3.3	Regressione lineare multipla	30
3.4	Feature scaling	30
3.5	Algoritmo di discesa del gradiente	31
3.5.1	Idea dell'algoritmo	31
3.5.2	Algoritmo generale	31
3.6	Regressione polinomiale e feature mapping	32
3.7	Regolarizzazione	32
3.8	Valutazione	32
3.8.1	REC curve	33
4	Classificazione	35
4.1	Introduzione alla classificazione	35
4.1.1	Classificazione: binaria e di classe	35
4.2	Classificazione binaria	35
4.2.1	Perché non usare la regressione lineare per la classificazione?	36
4.3	Regressione logistica - Sigmoidale	37
4.3.1	Vantaggi relativi all'uso della sigmoide	38
4.4	Funzione di Loss	38
4.4.1	Derivata parziale della funzione di costo	39
4.4.2	Entropia dell'informazione	39

4.4.3	Binary Cross Entropy Loss	40
4.5	Overfitting nella classificazione	41
4.6	Reject Region, regione d'incertezza	41
4.7	Classificazione multiclasse, approccio naive OVA e OVO	42
4.7.1	Metodo One vs All	42
4.7.2	Metodo One vs One	42
4.7.3	Confronto tra <i>One vs All</i> e <i>One vs One</i>	43
4.8	Stochastic Gradient Descent	43
4.9	Softmax - Classificazione Multiclasse	44
4.9.1	Definizione	44
4.9.2	Funzione Softmax	44
4.9.3	Funzione di Costo	45
4.9.4	Obiettivo di Learning	45
4.9.5	Proprietà del Softmax	45
4.9.6	Rete neurale Softmax	46
4.9.7	Funzione di Loss	46
5	Design, valutazione e scelta dei parametri di un algoritmo di ML	49
5.1	Momento e gradiente	49
5.2	Design di Algoritmi	49
5.2.1	Strategie di miglioramento	50
5.3	Valutazione	50
5.3.1	Valutazione incrociata	51
5.3.2	Bias e Varianza	53
6	Introduzione alle reti neurali	57
6.1	Definizione di rete neurale	57
6.2	Le funzioni di attivazione	59
6.2.1	Il teorema di approssimazione universale - <i>Universal Approximation Theorem</i>	59
6.3	Training e inferenza di una rete neurale	60
6.3.1	Funzione di costo	60
6.3.2	Chain Rule	61
6.3.3	Inizializzazione dei parametri	61
6.3.4	Reti neurali per regressione	61
6.4	Overfitting e Underfitting nelle reti neurali	61
7	Decision Tree	63
7.1	Alberi di classificazione	63
7.1.1	Divisione ricorsiva	63
7.1.2	Migliore divisione dei nodi	64
7.2	Alberi di regressione	65
7.2.1	Costruzione dell'albero di regressione	65

7.2.2	Divisione di un nodo	66
7.3	Pruning: riduzione dell'albero	67
7.3.1	Pre-pruning	67
7.3.2	Post-pruning	68
7.4	Regole di learning	68
7.4.1	Rule induction	68
7.4.2	Copertura delle regole	69
7.5	Alberi decisionali multivariati	69
7.5.1	Alberi decisionali multivariati lineari	70
7.5.2	Interpretazione geometrica	70
7.5.3	Alberi decisionali multivariati non lineari	70
8	Random Forests, Ferns, Meta-Algoritmi	73
8.1	Meta algoritmi nel machine learning	73
8.2	Decision stump - Ceppo di decisione	74
8.3	Decision Trees	74
8.4	Random Ferns	74
8.5	Random Tree	75
8.5.1	Randomized learning	75
8.6	Random forest	75
9	SVM: Support Vector Machines	77
9.1	Iperpiani di separazione	77
9.1.1	Funzione di decisione lineare	77
9.1.2	Interpretazione geometrica	78
9.2	Primal SVM	79
9.2.1	Concetto di margine	79
9.3	Soft Margin SVM	81
9.3.1	Soft Margin SVM e Loss function	82
9.4	Dual SVM	83
9.4.1	Convex duality con Moltiplicatori di Lagrange	83
9.5	Kernel Trick	86
9.5.1	Trasformare i dati	86
9.5.2	Il <i>Kernel Trick</i>	86
10	Ensemble Learning	89
10.1	Tipi di Ensemble Learning	89
10.1.1	Averaging	89
10.1.2	Weighted Averaging	90
10.1.3	Gating	90
10.1.4	Stacking	91
10.2	Tecniche di Manipolazione dei Dati	92
10.2.1	Bootstrap replication	92

10.2.2	Bagging	92
10.2.3	Boosting	92
10.3	AdaBoost	92
10.3.1	Algoritmo	93
10.3.2	Decision Boundary	94
III	Materiale aggiuntivo	97
A	Approfondimenti teorici	99
A.1	Problema della separabilità non lineare nel percettrone	99
A.2	Generalizzazione funzione di costo del softmax	100
B	Seminario 1: <i>Data and AI Law</i>	103
B.1	L'importanza dei dati - segreti industriali	103
B.1.1	Data Is The New Oil	103
B.1.2	<i>Mission Genesis</i> - 25 Novembre 2025	103
B.1.3	Norme: Data Protection e Copyright	104
B.2	Data Protection	104
B.2.1	GDPR - La rivoluzione	104
B.2.2	Sui Cookies	105
B.3	Copyright e diritto d'autore	105
B.3.1	Diritto d'autore	105
B.3.2	Alla tutela del Software	106
B.4	AI e Copyright	106
B.4.1	Posizioni dell'US Copyright Office	107
B.4.2	In Italia	107
B.4.3	<i>Un primo passo</i> - In Sud Africa	107
B.4.4	AI e soggettività giuridica	107
B.4.5	Caso OpenAI	107
B.5	AI e opere derivate	107
B.6	AIG e addestramento	108
B.6.1	Caso New York Times e OpenAI	108
B.6.2	FIEG contro Google AI	108
B.7	AI Act	108
B.8	AI Risk Pyramid	108
B.9	L'Italia	109
B.9.1	<i>"-umano"</i> - Aggiunta all'articolo 1	109
B.9.2	Reati relativi all'uso dei dati	109
B.10	Una soluzione ai problemi	109

C Seminario 2: <i>Computer Vision and Medical Imaging</i>	111
C.1 Intelligenza Artificiale	111
C.1.1 Machine Learning	111
C.1.2 Machine learning e Deep Learning	111
C.2 Caso studio 1: radiomica	112
C.2.1 Pipeline radiomica	112
C.2.2 Work 1: feature extraction	113
C.2.3 Work 2: Dynamic Feature Selection (DFS)	113
C.2.4 Work 3: Federated Feature Selection	113
C.3 Caso studio 2: immagini di cellule del sangue nei vetrini	114
C.4 Machine Learning is not dead.	114

Parte I

Concetti preliminari

Da definire.

Parte II

Teoria, algoritmi e modelli di Machine Learning

Capitolo 1

Introduzione al Machine Learning

1.1 Prime definizioni di Machine Learning

1.1.1 Arthur Samuel - 1959

Nel 1959, Arthur Samuel fornisce una **definizione di machine learning**: il machine learning è il campo di studi che abilita i computer ad **imparare, senza essere esplicitamente programmati**.

Il paradigma alla base è fortemente diverso da quello tipico: se un algoritmo classico è **programmato ad hoc** per risolvere un task, e si comporta in maniera prettamente **deterministica**, un algoritmo di machine learning può **imparare a risolvere problemi** associati a vasti set di dati (classificare elementi, riconoscerli, trovare correlazioni). Questo permette di spostare il nostro focus non più sullo sviluppo di tutti gli step necessari affinché un algoritmo risolve **un problema specifico**, ma sulla creazione di un modello che riesca ad apprendere come risolvere **un insieme di problemi simili**.

1.1.2 Perché abbiamo bisogno del Machine Learning

L'approccio utilizzato finora per risolvere i problemi è quello di:

- Trovare una logica per risolvere il problema.
- Scrivere un programma.
- Suddividerlo in pezzi più piccoli (funzioni).
- Automatizzare l'approccio.

Questo funziona per problemi di natura fortemente univoca, che sappiamo come risolvere, ad esempio:

- Computare l'area di un poligono.
- Risolvere equazioni differenziali.

Nel caso del poligono, supponendo di voler calcolare l'area di un rombo i dati presi in input sarebbero dati dalla coppia (x_1, x_2) , contenente le lunghezze della diagonale principale

e secondaria. Questi dati, passati ad un algoritmo, permettono di calcolarne l'area $\frac{x1*x2}{2}$ e generarne un output

Dati $\rightarrow$ Programma che risolve un task $\rightarrow$ Output

Alcuni problemi tuttavia presentano un alto grado di **incertezza**, che li rende più difficili da affrontare. Non poter fare assunzioni sui dati in input, e non conoscere tutti i possibili task, rende impossibile l'utilizzo di algoritmi standard per compiti del tipo:

- Classificazione di email spam e non spam
- Object detection

Il machine learning rappresenta la soluzione ideale a problemi di questo tipo, proponendo una nuova pipeline:

Dati + Output Atteso $\rightarrow$ Machine Learning $\rightarrow$ Soluzioni su nuovi dati

1.1.3 Esempio delle email spam e non-spam

Vogliamo creare un algoritmo di machine learning in grado di determinare se una mail è spam o meno. Il nostro obiettivo è quindi classificare ciascuna di queste come **spam**, o **ham**¹.

- Compra prodotto a 10\$! 0ferta imperdibile! $\rightarrow$ Spam
- Ciao Giovanni, come stai? $\rightarrow$ Ham

1.1.4 Tom Mitchel - 1998

Un algoritmo **apprende dall'esperienza** E rispetto a una certa classe di **Task** T e a una misura di **performance** P . Se la sua **performance** nel compito T , misurata tramite P , migliora con l'**esperienza** E , allora quel modello ha appreso con successo.

1.2 Definizioni fondamentali

1.2.1 Definizione di Task

Rappresenta il problema che deve essere risolto. Nell'esempio di determinare se una mail è spam o meno, il task è quello di **predire** l'etichetta ($Y = \text{"spam"}$ oppure $Y = \text{"ham"}$), ed è strettamente legata al modello, che rappresentiamo come funzione parametrizzata, indicata con h_θ .

1.2.2 Definizione di Esperienza

Rappresentano i dati, ovvero i valori assunti dalle **random variables**, nell'esempio X è il contenuto della mail ed Y l'etichetta. La coppia di valori:

¹Email legittima, non spam.

$$\{(X = x_i, Y = y_i)\}_{i=1}^N$$

Rappresenta l'esperienza. Generalmente vista come una collezione di elementi chiamati **esempi**.

1.2.3 Definizione di Performance

Funzione P che **valuta quanto bene** il modello è in grado di **risolvere un certo task** T . Supponiamo che il nostro algoritmo abbia previsto un insieme di etichette per un dato numero di email che indichiamo con:

$$\{\hat{y}_i\}$$

Dove il simbolo 'hat' indica che il dato non è stato osservato ma **previsto**. L'insieme delle etichette corrette è invece dato da

$$\{y_i\}$$

Per valutare la qualità del nostro metodo, dovremmo confrontare i due insiemi di previsioni utilizzando una **misura di performance**:

$$P(\{y_i\}, \{\hat{y}_i\})$$

Questa funzione restituisce un valore reale appartenente al range $[0,1]$.

- Un **valore elevato** indica che le previsioni sono accurate
- Un **valore basso** indica che le previsioni non sono accurate.

Indichiamo con il termine **misura di errore** il valore: $1 - P$. Per risolvere problemi di machine learning ci affidiamo a modelli statistici che dipendono dal task.

1.2.4 Esempio completo

Siano:

- $x^{(1)}$: Il testo dell'email 1: "Compra prodotto a 10\$! Offerta imperdibile!"
- $x^{(2)}$: Il testo dell'email 2: "Ciao Giovanni, come stai?"
- $y^{(1)}$: L'etichetta **spam**
- $y^{(2)}$: L'etichetta **ham**
- h_θ : Il modello

Allora

$$h_\theta(x^{(1)}) = \hat{y}^{(1)}$$

e

$$h_{\theta}(x^{(2)}) = \hat{y}^{(2)}$$

1.3 Task, Esempi ed Etichette

Un esempio (o osservazione) è generalmente espresso come una raccolta di valori che sono stati misurati quantitativamente da un evento osservato. Un esempio è generato da un vettore:

$$x \in \mathbb{R}^d$$

Scritto anche come:

$$x = (x_1, x_2, \dots, x_d)$$

I valori del vettore x sono detti **features**, in quanto rappresentano **proprietà specifiche** degli esempi in input. Se la dimensionalità di x è 10, diremo che ha 10 features. Nella maggior parte dei casi, ogni esempio x è anche abbinato a un output desiderato y . Tali output desiderati, sono anche chiamati **etichette**. Un'attività può quindi essere definita come un certo modo di elaborare un esempio di input per ottenere un output.

Torniamo al nostro esempio: determinare se un'e-mail è spam o ham. In questo caso, l'input è l'email, le features possono essere caratteristiche dell'email, come il numero di errori ortografici o la presenza di alcune parole chiave, mentre l'output atteso è l'etichetta (spam o ham).

1.4 Features

1.4.1 Estrazione

Per gestire le email, dobbiamo prima trasformarle in un'entità **quantificabile**. Questo di solito viene fatto **identificando alcune caratteristiche** dei dati che sono **rilevanti per il compito dato** (numero di errori ortografici o la presenza di alcune parole chiave). In pratica, stiamo cercando una funzione f che trasformi l'entità dalla sua forma originale a una forma di destinazione, che è buona per risolvere un compito specifico:

$$x \rightsquigarrow f(x) \rightsquigarrow \bar{x}$$

Dove x è il dato grezzo di input (ad esempio, il messaggio di posta elettronica completo), f è la funzione di trasformazione e $\bar{x}$ è l'output della trasformazione, che sarà l'input dell'algoritmo di apprendimento automatico.

La funzione f è chiamata *rappresentazione*. L'output della trasformazione x è anche chiamato rappresentazione. Poiché rappresentando i dati otteniamo un vettore di funzionalità, il processo di rappresentazione dei dati è talvolta chiamato **features extraction**.

²Su questa notazione: da ora in poi, quando ci riferiremo all'output della trasformazione, non useremo più $\bar{x}$, ma direttamente x , dando per scontato il passaggio di rappresentazione $f(x)$.

Non ci sono «rappresentazioni universali», ma solo rappresentazioni che servono a qualche compito.

Le rappresentazioni sono di 2 tipi:

- Create a mano
- Apprese

L'estrazione delle features **mette in luce caratteristiche salienti** trascurandone altre.

1.4.2 Definizione formale

Generalmente, l'output di una funzione di rappresentazione è nella forma:

$$x = (x_1, x_2, \dots, x_d), \quad x \in \mathbb{R}^d$$

Questo, è composto da un insieme di features . **Una feature è la specifica di un attributo**. Si tratta di una misura che rappresenta **aspetti dei dati** che è utile **evidenziare per risolvere il problema considerato**. Ad esempio, il colore può essere un attributo. "Il colore è blu" è una funzionalità estratta da un esempio.

Le caratteristiche possono essere di due tipi principali:

Categoriche: un numero finito di valori discreti. Questi possono essere:

- **Nominali:** a indicare che non esiste **alcun ordinamento** tra i valori, ad esempio cognomi e colori.
- **Ordinali:** a indicare che esiste un **ordinamento rilevante**, ad esempio in un attributo che assume i valori basso, medio o alto.

Continue: comunemente, **sottoinsieme di numeri reali**, dove c'è una differenza misurabile tra i valori possibili. I numeri interi sono solitamente trattati come continui nei problemi pratici.

1.5 Esempio delle Email Spam e Non Spam

Consideriamo il nostro esempio in cui vogliamo distinguere le e-mail spam da quelle non spam. L'input del processo sono i messaggi di posta elettronica, quindi dobbiamo trasformarli in vettori di features:

$$x = (x_1, x_2, \dots, x_n)$$

con un processo di *features extraction*.

Naturalmente, ci aspettiamo che le funzionalità estratte siano **utili per risolvere il nostro compito** di determinare se un'e-mail è spam o ham. Possiamo notare che le e-mail di spam spesso includono errori ortografici e parole come "Acquista", "occasione" e "10\$". Quindi, potremmo decidere di rappresentare ogni messaggio di posta elettronica con due numeri:

- Il conteggio degli errori ortografici.
- Il numero di volte in cui alcune parole o pattern specifici appaiono nel testo.

Una volta che i messaggi di input sono stati convertiti in **vettori di funzionalità**, possono essere visti come **vettori nello spazio $\mathbb{R}^2$** .

FIGURA 1.1




Figura 1.1: Estrazione delle feature: le e-mail vengono trasformate in vettori 2D, dove x = errori ortografici e y = pattern ripetibili, e proiettate nello spazio delle feature, , dove la separazione tra spam (arancione) e non spam (verde) risulta evidente.

1.6 Tipologie di Task

Le attività possono essere di diversi tipi. Di seguito, discuteremo due compiti principali:

- **Classificazione**
- **Regressione**

Assumeremo che ogni algoritmo di apprendimento automatico prenda come input esempi che sono già stati rappresentati con una funzione di rappresentazione adeguata.

1.6.1 Classificazione

In questo tipo di attività, alla macchina viene chiesto di specificare a quale di un insieme predefinito di categorie K appartiene l'input.

Esempi di questo compito sono:

- Classificare i post di Facebook come riguardanti la politica o qualcos'altro (classificazione politica vs non politica).
- Rilevamento delle e-mail di spam (classificazione dello spam vs legittima delle e-mail).
- Riconoscimento dell'oggetto raffigurato in un'immagine tra 1000 oggetti diversi (riconoscimento dell'oggetto).

L'algoritmo di apprendimento è solitamente fornito con un insieme di esempi:

$$\{x^{(1)}, x^{(2)}, \dots, x^{(n)}\} \text{ dove: } x^{(j)} \in \mathbb{R}^N \forall j$$

e un insieme di etichette corrispondenti

$$\{y^{(1)}, y^{(2)}, \dots, y^{(n)}\} \text{ dove: } y^{(j)} \in \{1, \dots, k\} \forall j$$

che specificano a quale delle categorie K appartiene ogni esempio.

Ad esempio, se $y^{(j)} = 3$, allora $x^{(j)}$ appartiene alla classe "3".

Nel caso della classificazione binaria (ad esempio, spam vs non spam), $y^{(j)} \in \{0, 1\}$. Per risolvere questo compito, l'algoritmo di apprendimento automatico assume la forma di una funzione:

$$h_{\theta} : \mathbb{R}^N \rightarrow \{1, \dots, K\}$$

tale che:

$$y^{(j)} = h_{\theta}(x^{(j)})$$

Esempio:

- **Classification Task:** data un'e-mail, classificarla come spam o non spam.
- **Input:** esempi n -dimensionali $x = (x_1, x_2, \dots, x_n)$ contenenti le caratteristiche dell'email, come il numero di errori ortografici e l'occorrenza di parole specifiche.
- **Output:** etichette $y \in \{0, 1\}$ che indicano se l'e-mail è legittima o spam.

Alcuni algoritmi di classificazione **non prevedono un output discreto**, ma un vettore di **probabilità**, contenente la probabilità relativa a ciascuna delle etichette possibili. In questo caso, puntiamo ad avere la probabilità massima nello slot del vettore relativo all'etichetta vera.

1.6.2 Regressione

In questo tipo di compito, al programma del computer viene chiesto di **prevedere un valore numerico dato un input**, tipo:

- Prevedere il prezzo delle case date alcune caratteristiche come la città, l'età, la zona, ecc.
- Prevedere il valore futuro delle azioni di una società dai valori di altre società o da altre statistiche sul mercato (previsione del mercato azionario).
- Conta il numero di auto presenti in un'immagine.

Analogamente alla classificazione, l'algoritmo viene fornito con esempi di training $x \in \mathbb{R}^N$ e con gli output desiderati $y \in \mathbb{R}$. L'algoritmo di apprendimento automatico assume la forma di una funzione $h_{\theta} : \mathbb{R}^N \rightarrow \mathbb{R}$ tale che $y^{(j)} = h_{\theta}(x^{(j)})$.

Esempio:

- **Regression task:** Predire il prezzo di una casa in base ai suoi metri quadrati.

- **Input:** Dimensione della casa x (valore scalare)
- **Output:** Prezzo y .

Sono algoritmi ottimi per trovare relazioni tra i dati ed effettuare previsioni.




Figura 1.2: Relazione tra dimensione dell'immobile ($x_1^{(i)}$, in mq) e prezzo ($y^{(i)}$, in migliaia di \$): i punti rossi sono i dati osservati, la linea blu rappresenta un modello di regressione lineare che non approssima bene l'andamento non lineare.

1.7 Tipi di Machine Learning

1.7.1 Supervised Learning e Unsupervised Learning

Gli approcci di Machine Learning possono essere approssimativamente divisi in **supervised** e **unsupervised learning**.

Supervised Learning: L'algoritmo viene addestrato su un insieme di esempi di input e **output desiderati**. L'obiettivo è allenare un modello a mappare gli input agli output corretti. Il punto chiave qui è il conoscere gli output desiderati: i dati del nostro dataset dovranno quindi essere preventivamente **etichettati**.

Unsupervised Learning: L'algoritmo viene addestrato solo su esempi di input, senza output desiderati. L'obiettivo è trovare struttura, pattern e associazioni nei dati, spesso molto eterogenei.

$$\{x^{(1)}, x^{(2)}, \dots, x^{(n)}\} \quad \text{dove: } x^{(j)} \in \mathbb{R}^N \forall j$$

Questi tipi di compiti mirano generalmente a **modellare la struttura dei dati**. Un esempio di unsupervised learning è il **clustering**, in cui non viene fornita alcuna informazione aggiuntiva oltre agli esempi.

Gli approcci supervised sono generalmente più facili da gestire, ma richiedono la presenza di **labels**. Ottenere labels è spesso un problema costoso in termini di tempo,

poiché richiede che le persone annotino manualmente i dati. Ad esempio, se dobbiamo costruire un spam-detector utilizzando un approccio supervised, è necessario che qualcuno etichetti manualmente diverse email come ‘spam’ o ‘non-spam’.

1.7.2 Reinforcement Learning

Alcuni autori fanno riferimento anche a una terza classe di algoritmi di Machine Learning: il **Reinforcement Learning**.

Il Reinforcement Learning mira a **scoprire la soluzione a un problema** attraverso il metodo *trial and error*, piuttosto che tramite istruzioni esplicite su come risolvere il compito. Questo avviene permettendo all'algoritmo di **interagire con un environment** e ricevere **positive rewards** quando compie azioni che portano a un buon risultato (rispetto al problema da risolvere) e **negative rewards** quando compie azioni che portano a un risultato negativo.

L'obiettivo degli algoritmi di Reinforcement Learning è apprendere una policy π , che possa essere utilizzata per **determinare quale azione a intraprendere** quando si acquisisce un'osservazione del mondo o . Questo processo ricorda il modo naturale in cui gli animali imparano a risolvere problemi. Ad esempio, si può pensare a un topo che deve trovare l'uscita da un labirinto (immagine 1.3).




Figura 1.3: Reinforcement Learning nel labirinto: l'agente sceglie tra azioni U/D/L/R e apprende una policy $\pi(o) = a$ che massimizza la ricompensa, raggiungendo il formaggio (positiva) ed evitando il gatto (negativa).

1.8 Misura di Performance (P)

Per valutare le capacità di un algoritmo di Machine Learning nel risolvere un determinato compito, è necessaria una misura quantitativa delle sue prestazioni. Solitamente, questa **performance measure** P è **specifica per il task** T che il sistema sta eseguendo.

Per compiti come la classification, spesso si misura la performance utilizzando l'**accuracy**, ovvero la percentuale di esempi classificati correttamente dal modello. Nel caso della regression, invece, si possono usare altre metriche come il mean squared error.

Le misure di performance sono utilizzate per due motivi principali:

- Capire quando un algoritmo di Machine Learning sta migliorando in un determinato compito.
- Valutare la performance dell'algoritmo una volta finalizzato.

Una performance measure può anche essere vista in termini di error. Ad esempio, l'**accuracy** corrisponde a un error rate (la percentuale di esempi classificati in modo errato), calcolato come $1 - accuracy$.

1.8.1 Esempio

Un spam detector analizza cinque email. Le prime tre sono spam, le ultime due non lo sono. L'algoritmo classifica come spam le prime due email e come non spam le ultime tre. In questo caso, la prima e le ultime due classificazioni sono corrette, mentre la terza è errata. La accuracy si calcola come la percentuale di esempi classificati correttamente:

$$\frac{4}{5} = 0.8 \quad \text{ovvero} \quad 80\%$$

1.9 Elementi fondamentali del Machine Learning

1.9.1 Experience (E)

Un algoritmo di Machine Learning apprende dall'**experience** per migliorare una performance measure su un determinato task.

L'**experience** è costituita da una raccolta di esempi

$$x^{(i)}$$

(noti anche come data points, poiché possono essere mappati in uno spazio multi-dimensionale tramite una funzione di rappresentazione), eventualmente accompagnati dalle relative labels

$$y^{(i)}$$

(a seconda del task considerato).

Esistono due principali tipi di algoritmi di Machine Learning:

- Supervised approaches (quando abbiamo le paired labels, ad esempio nella classification e nella **regression**).

- Unsupervised approaches (quando non abbiamo paired labels, come nel **clustering**).

L'**experience** assume forme diverse a seconda del tipo di approccio di Machine Learning utilizzato.

1.9.2 Dataset (D)

Le performance measures vengono generalmente calcolate rispetto a un insieme di esempi, piuttosto che su singoli esempi. Un insieme di esempi (eventualmente con labels) è chiamato **dataset**. I datasets sono generalmente omogenei, nel senso che i dati contenuti al loro interno hanno un formato simile. Ad esempio:

- Nel Fisher's Iris dataset, tutti gli esempi hanno 4 features e una label corrispondente a una delle tre classi.
- In un dataset di immagini di food, ogni immagine è associata a una class che indica il piatto specifico.

1.9.3 Design Matrix

Un modo comune per rappresentare un dataset è utilizzare una design matrix. Poiché ogni esempio è una collezione di n features, un dataset di m elementi può essere rappresentato tramite una matrice

$$X \in \mathbb{R}^{m \times n}, m, n \in \mathbb{N}$$

di dimensione $m \times n$.

- Ogni riga della design matrix rappresenta un esempio.
- Ogni colonna rappresenta una delle features.

Nel caso del supervised learning, si considera spesso anche un'altra matrice

$$Y \in \mathbb{A}^{m \times k}, k \in \mathbb{N}$$

dove k è la dimensionalità degli output desiderati.

Ad esempio, nel caso della classification,

$$\mathbb{A} = \{1, \dots, M\}$$

dove M è il numero di classi e k è spesso uguale a 1.

1.9.4 Esempio

Supponiamo di avere un dataset composto da 1000 email, alcune classificate come spam e altre come not spam. Assumiamo che ogni email sia rappresentata da due features, come discusso nei precedenti esempi.

La design matrix che rappresenta il dataset è una matrice

		j^{th} feature										
$X =$	i^{th} example {	2.2	4.7	3.8	9.2	4.7	3.2	-1.2	8.9	-0.11	4.12	2
		-0.11	-1.2	-0.11	-1.2	-0.11	4.7	-1.2	4.7	-0.11	9.2	3
		9.2	-0.11	9.2	4.12	9.2	9.2	-1.2	6.9	-1.2	9.2	8
		9.2	9.2	-0.11	-1.2	4.12	-8.6	9.2	-0.11	4.7	9.2	2
		-0.15	9.2	-1.2	-0.11	4.7	-0.11	-1.2	8.7	9.2	-87.5	1
		-0.11	-1.2	4.7	4.7	9.2	4.7	4.12	9.2	9.2	-1.2	0
		9.2	-0.11	9.2	9.2	-1.2	4.7	4.7	-0.11	-1.2	-0.11	8
		9.2	-0.11	4.12	-1.2	32.5	-1.2	9.2	9.8	4.12	9.2	1
												$Y =$

Figura 1.4: Design Matrix: rappresentazione di un dataset con m esempi e n features. Ogni riga corrisponde a un esempio, ogni colonna a una feature.

$$X \in \mathbb{R}^{1000 \times 2}$$

- Ogni elemento della matrice rappresenta una delle features di un esempio nel dataset.
- Ad esempio, $X_{i,1}$ indica il numero di **errori** ortografici nell' **i -esima email**, mentre $X_{j,2}$ rappresenta il numero di **occorrenze** di parole chiave nell' **j -esima email**, e così via.

Le labels sono contenute in un vettore

$$Y \in \{0, 1\}^{1000}$$

dove Y_i rappresenta la label associata all' **i -esimo esempio** (ad esempio, 0 = not spam, 1 = spam).

1.9.5 Learning

Un algoritmo di Machine Learning **utilizza un dataset di esempi per migliorare la sua performance** in un determinato **task**. Il processo di miglioramento della performance dell'algoritmo è chiamato **learning** o **training**.

In cosa consiste il training?

- Un algoritmo di Machine Learning ha alcuni parametri chiamati *parameters*, che possono essere regolati per modificarne il comportamento. Questi parametri sono legati a un *model* (una funzione matematica) utilizzata per risolvere il *task*.
- Un algoritmo chiamato *training procedure* utilizza gli esempi forniti per trovare i valori ottimali per questi *parameters*.
- Alcuni parametri non possono essere regolati automaticamente dal *training*. Questi sono detti *hyperparameters* e devono essere ottimizzati al di fuori della *training procedure*, spesso attraverso un metodo *trial and error*.

Esempio. Consideriamo un semplice spam detector che classifica le email come spam o non-spam in base al numero di errori ortografici.

L'algoritmo può essere scritto come segue:

```
1 def classify(x):  
2     if x > a:  
3         return 1 # Spam  
4     else:  
5         return 0 # Non-spam
```

Listing 1.1: Soglia sul numero di errori ortografici, chiaramente un approccio naive

L'algoritmo dipende da un singolo parametro a . La domanda è: quale valore dovremmo assegnare ad a ? La *training procedure* permette di trovare un valore ottimo presumibilmente adatto per a . Una semplice *training procedure* consisterebbe nel provare diversi valori per a e registrare le performance dell'algoritmo per ciascun valore di a . Alla fine, possiamo scegliere il valore di a che massimizza la performance measure P .

1.9.6 Il paradigma Training/Testing

Ciascun algoritmo di Machine Learning presenta al suo interno dei parametri. Una scelta opportuna dei parametri, dovrebbe garantire il funzionamento del modello. La procedura generale, per la scelta e la verifica dei parametri dell'algoritmo, è suddivisa in due parti:

1. Training dell'algoritmo.

Effettuato usando i dati dell'omonimo **training set**, consiste nella scelta dei parametri del modello, vedendo ogni volta i valori della *loss function*, o funzione di costo, che offre un'indice dell'errore da parte del modello, permettendo di capire se i parametri vanno modificati, e di quanto.

2. Testing dell'algoritmo - Inferenza.

Passiamo ora ai dati di testing, usati per verificare se i parametri scelti sul dataset di training, sono opportuni su dati mai visti prima. Andremo a valutare quindi il nostro modello, secondo quelle che chiamiamo **misure di valutazione**.

Suddivisione dei dati

Come accennato in precedenza, distinguiamo due insiemi di dati: i **dati di training** e i **dati di testing**. È importante che i dati usati in fase di training, e i dati usati in fase di inferenza, siano **totalmente disgiunti**.

$$\text{Training} \cap \text{Testing} = \emptyset$$

Tuttavia, entrambi i set di dati appartengono in origine all'insieme X . La suddivisione dei dati in training e testing sarà effettuata randomicamente, in modo da evitare bias di qualsiasi tipo. Dobbiamo inoltre assicurarci che il numero di dati, per ogni etichetta, sia uguale. Prendere l'80% di un dataset in fase di testing, con due classi (Cane, non-cane), significa prendere l'80% di ciascuna delle due classi. L'obiettivo è **evitare favoritismi** durante la classificazione. Parleremo più avanti di tecniche che stabiliscono come effettuare la suddivisione tra training e testing, sfruttando al meglio i propri dati, come la k -fold cross-validation.

1.9.7 Normalizzazione

I nostri dati $x \in \mathbb{R}^d$ possono avere valori appartenenti a range molto ampi, con range diversi per ciascuna di queste features. Per creare spazi in cui le features hanno più o meno la stessa dimensione, si usano delle strategie di normalizzazione, come di seguito.

Normalizzazione in $[0, 1]$. Per ogni j -esima feature, dobbiamo andare a stabilire il minimo e il massimo del dataset. Dato un dataset di dimensione m :

$$\begin{aligned} x_j^{\min} &= \min\{x_j^{(i)} \mid i = 1, 2, \dots, m\}, \\ x_j^{\max} &= \max\{x_j^{(i)} \mid i = 1, 2, \dots, m\}. \end{aligned}$$

Possiamo quindi normalizzare secondo la seguente formula:

$$\hat{x}_j = \frac{x_j - x_j^{\min}}{x_j^{\max} - x_j^{\min}},$$

e ogni dato sarà $\hat{x}_j \in [0, 1]$.

Standardizzazione in $[-1, 1]$.

$$\hat{x}_j = \frac{x_j - \mu_j}{\sigma_j}$$

con σ_j varianza. Il risultato è un centramento a $(0, 0)$ dei nostri dati. L'origine coinciderà con la nostra media. Ogni dato sarà $\hat{x}_j \in [-1, 1]$.

Quantità statistiche per la j -esima feature

Per completezza, riportiamo le definizioni delle quantità usate sopra:

$$\text{Media: } \mu_j = \frac{1}{m} \sum_{i=1}^m x_j^{(i)},$$

$$\text{Varianza: } \text{Var}(x_j) = \frac{1}{m} \sum_{i=1}^m (x_j^{(i)} - \mu_j)^2,$$

$$\text{Deviazione standard: } \sigma_j = \sqrt{\frac{1}{m} \sum_{i=1}^m (x_j^{(i)} - \mu_j)^2} = \sqrt{\text{Var}(x_j)}.$$

Bisognerà conservare rispettivamente $x_j^{\min}, x_j^{\max}$ o μ_j, σ_j , per permettere la normalizzazione del testing set, in quanto la normalizzazione è fatta in fase di training.

1.10 Iperparametri

Sono dei parametri che stabiliscono aspetti del nostro modello, e che non sono calcolati in fase di training. In fase di training, questi vengono fissati, e **non influiscono sul training**. Nonostante ciò, gli iperparametri avranno un effetto sulla nostra loss-function. Bisognerà variare gli iperparametri usando un **validation set**, un terzo set di dati sempre ottenuto dal dataset X .

1.10.1 k-fold Cross Validation

È una strategia che permette di ottenere ottimi risultati anche con dataset più piccoli. Dividiamo in due parti il nostro dataset X , ottenendo l'insieme di training e l'insieme di testing. Dividiamo nuovamente l'insieme di **training** in k parti. Supporremo $k = 3$. Utilizzeremo un $\frac{1}{k}$ per la validazione e le $\frac{k-1}{k}$ rimanenti come training. In questo caso, $1/3$ e $2/3$. Effettueremo tre volte training e validazione, variando ogni volta il subset usato per la validazione e quelli usati per il testing. Da ciascuno dei processi di training, emergerà un valore della loss function: sceglierò gli iperparametri associati a valori della loss function più bassi.

1.11 Overfitting e underfitting

Sono tra i problemi più grandi che possono emergere con i propri algoritmi di machine learning, e riguardano spesso la **scelta del modello**.

Overfitting Generalmente si parla di overfitting, quando il modello è così complesso da offrire performance ottime in fase di training (impara facilmente e bene), ma fortemente **peggiori in fase di testing**: il modello è così complesso da imparare troppo bene i dati su cui ha appreso, ma da pessime performance sui dati inediti.




Figura 1.5: Procedura di cross-validation con $k=5$.

Underfitting Caratterizzato da **pessime performance in fase di training**, troppe poche variabili, modello troppo semplice. L'apprendimento non è tale da permettere al modello di conoscere il proprio dataset. Il modello non impara!

Bisogna quindi trovare lo *sweetspot*, il compromesso, tra i modelli più complessi, e quelli più semplici. Il numero di parametri è un fattore da tenere sempre in considerazione.

1.11.1 Bias e Variance




Figura 1.6: In blu i dati di training, in rosso quelli di testing. Nel caso dell'underfitting, vediamo una funzione troppo semplice (una funzione lineare) per approssimare una funzione più complessa. Nel caso dell'overfitting, il modello dà output assurdi.

Osservando i risultati dei nostri modelli, sarà possibile individuare facilmente due tipologie di errori:

Bias Error. Le previsioni non sono corrette a causa di assunzioni errate nel modello. Un alto bias può portare il modello a non rilevare importanti relazioni tra le features e gli

output target, portando a underfitting (es. un modello che cerca di approssimare una funzione polinomiale con una lineare). Usare modelli con alto bias causa underfitting.

Variance Error. Le previsioni del modello sono fortemente influenzate da piccole fluttuazioni nel training set. Ad esempio, se rimuoviamo un punto dati e riaddestriamo l'algoritmo, otteniamo previsioni molto diverse. Questo può essere dovuto al fatto che l'algoritmo sta cercando di modellare il rumore casuale presente nei dati di training, il che di solito porta a overfitting.

Riferimenti

Il materiale visto in questo capitolo comprende:

- Materiale visto a lezione.
- Note scritte dal prof. Antonino Furnari.

Capitolo 2

I primi modelli di Machine Learning

2.1 Neurone computazionale - modello di McCulloch-Pitt

L'idea iniziale era quella di replicare la struttura di un neurone biologico con un modello matematico, in modo da poter simulare il funzionamento del cervello umano.


Neurone biologico. Un neurone biologico è costituito da:

- Dendriti: ricevono segnali da altri neuroni.
- Corpo cellulare: elabora i segnali ricevuti.
- Assone: trasmette il segnale elaborato ad altri neuroni.


Il primo modello di neurone computazionale fu proposto da McCulloch e Pitts nel 1943. Si basa su tre componenti principali:

- Degli input $x_1, x_2, \dots, x_d$ binari, che possono essere **eccitatori** e **inibitori**.
- Una threshold v , una soglia
- Un output binario.

Neurone Computazionale di McCulloch Pitt



AND Logico



OR Logico




Figura 2.1: Modello di McCulloch Pitt e due computazioni possibili: AND logico e OR logico

Supponiamo che $x_1, \dots, x_j$ siano eccitatori, $x_{j+1}, \dots, x_d$ sono inibitori. Se $j \geq 1$ e almeno un inibitore è $= 1$, allora il neurone ritorna 0. Un inibitore è sufficiente per bloccare

l'output. Altrimenti, si calcola $z = x_1 + \dots + x_j = x_1 + \dots + x_d$, ossia la somma di tutti gli input¹. Se la somma è $\geq v$, allora l'output sarà 1, altrimenti 0.

Questo modello è tale da poter computare un *AND* ($v = n$ e n input eccitatori), un *OR* ($v = 1$ e n input eccitatori, vedere figura 2.1), ma non uno *XOR*!

2.1.1 Limitazioni del modello di McCulloch-Pitt

- Non esiste un modo automatico di fare training.
- Gli input sono binari.
- Gli input hanno tutti lo stesso peso.
- Tutte le funzioni computabili sono linearmente separabili.

2.2 Percettrone - Rosenblatt

Il successore del modello di McCulloch-Pitt è il **percettrone**. Questo modello risolve il problema dei pesi, assegnando ad ogni ingresso un peso differente, e introduce una procedura di apprendimento automatico per stabilire i pesi in maniera opportuna.




Figura 2.2: Modello di Rosenblatt, noto come Percettrone

Le componenti sono:

- Features $x_1, x_2, \dots, x_d$ normalizzate in $[0, 1]$. Ciascuno di questi input ha associato un peso $v_1, \dots, v_d$.
- Una threshold v_0 , una soglia.

¹posso considerare anche gli input degli inibitori in quanto $= 0$.

- Un output binario.
- Una **procedura di learning automatico** per stabilire i parametri (il peso di ciascun input).

Il comportamento del percettrone sarà il seguente:

$$f(x_1, \dots, x_d) = \begin{cases} 1 & \sum_{j=1} x_j v_j \geq \vartheta_0 \\ 0 & \text{altrimenti} \end{cases}$$

Per semplificare la computazione, verrà aggiunta una feature $x_0 = 1$ con peso ϑ_0 , uguale alla threshold. Questo ci aiuterà a scrivere la funzione con la seguente notazione:

$$f(x_1, \dots, x_d) = \begin{cases} 1 & \sum_{j=1} x_j v_j \geq 0 \\ 0 & \text{altrimenti} \end{cases}$$

E poi come prodotto matriciale:

$$f(x) = [\vartheta^T \bar{x} > 0]$$

dove ϑ^T è il vettore dei pesi. Supponiamo ora di avere 2 parametri, andremo a ottenere:

$$\vartheta_0 + x_1 \vartheta_1 + x_2 \vartheta_2 \geq 0$$

e con dei semplici passaggi, possiamo tracciare una retta nello spazio, chiamata **decision boundary**, che dividerà lo spazio in due parti, quella per cui $f(x_1, \dots, x_d) = 1$, e quella per cui $f(x_1, \dots, x_d) = 0$

$$x_2 = x_1 \frac{\vartheta_1}{\vartheta_2} + \frac{\vartheta_0}{\vartheta_2}$$




Figura 2.3: Decision boundary del percettrone in 2D. I punti arancioni sono classificati come 1, quelli blu come 0 e la retta al centro è la *decision boundary*.

Questa retta, in un task di classificazione, suddivide lo spazio in due classi. In uno spazio 2D è una retta, in uno spazio 3D un piano. Lo spazio dovrà essere **linearmente separabile**.

2.2.1 Processo generale di training del perceptrone

Descriviamo la procedura di training nel seguente modo:

1. Inizializzazione casuale dei pesi $\vartheta_1, \dots, \vartheta_d \in \mathbb{R}$.
2. Computa $\forall x^{(i)}$ il valore di $\hat{y}^{(i)}$.
3. Confronta $\hat{y}^{(i)}$ con $y^{(i)}$
 - Se $\hat{y}^{(i)} = y^{(i)}$: non fare nulla.
 - Se $\hat{y}^{(i)} \neq y^{(i)}$: vanno aggiornati i pesi. Analizziamo come modificare i pesi, in funzione dei risultati.
4. Aggiornamento dei pesi:

$\hat{y}^{(i)}$	$y^{(i)}$	Cosa fare
0	0	ok!
0	1	riduci i pesi.
1	0	aumenta i pesi.
1	1	ok!

Questo sposterà la retta in maniera opportuna, convergendo ad un risultato opportuno per il dataset di training.

Questa descrizione generale riflette a grandi linee il processo, tuttavia è opportuno conoscere la procedura dal punto di vista matematico, che riflette poi l'implementazione effettiva.

2.2.2 Implementazione del training

L'aggiornamento dei pesi avviene nel seguente modo:

$$\underbrace{\hat{\vartheta}_j}_{\text{nuovo peso}} \leftarrow \vartheta_j + (y^{(i)} - \hat{y}^{(i)})x_j$$

Chiaramente, il perceptrone non dovrà modificare i suoi pesi se $\hat{y}^{(i)} = y^{(i)}$. Questa formula lo contempla, in quanto $y^{(i)} - \hat{y}^{(i)} = 0$: il peso non verrà aggiornato. Si può aggiungere un parametro α , detto **learning rate**. Il perceptrone standard non lo prevede.

$$\hat{\vartheta}_j \leftarrow \vartheta_j + \alpha(y^{(i)} - \hat{y}^{(i)})x_j$$

Scelto in maniera opportuna, potrebbe migliorare l'apprendimento e la convergenza.

2.2.3 Versione di Adaline

Una versione successiva dell'algoritmo di ricalcolo dei pesi, per stabilire con maggiore precisione di quanto incrementare o decrementare i pesi, stabilisce che

$$\hat{\vartheta}_j \leftarrow \vartheta_j + \left(y^{(i)} - \sum_i \vartheta_i \cdot x_i \right) x_j$$

Osserviamo che, per ogni esempio i -esimo, l'uscita desiderata $y^{(i)}$ può assumere solo due valori, 0 oppure 1. Allo stesso tempo, la somma pesata

$$\sum_i \vartheta_i \cdot x_i$$

rappresenta una combinazione lineare normalizzata degli ingressi, e pertanto assume valori compresi nell'intervallo $[0, 1]$. Ne consegue che la differenza tra il valore target $y^{(i)}$ e la somma pesata non potrà che appartenere all'intervallo $[-1, 1]$. In altre parole, se il neurone commette l'errore massimo possibile, questo sarà pari a 1 in valore assoluto, cioè la distanza più grande tra un'uscita binaria (0 o 1) e un valore previsto all'interno di $[0, 1]$.

2.3 Modelli lineari

Il percettrone funziona correttamente solo se i dati sono *linearmente separabili*, ovvero se esiste una frontiera lineare che separa le due classi. Ad esempio, il problema AND è linearmente separabile.

Nota. può essere trovato un approfondimento sulla separabilità lineare nell'appendice A, sezione A.1.

2.3.1 Problema dello XOR

Supponiamo però di voler computare lo XOR logico. Per farlo, costruiamo la tabella:

x_1	x_2	$XOR(x_1, x_2)$
0	0	0
0	1	1
1	0	1
1	1	0

Il problema XOR non è linearmente separabile (immagine 2.4): i quattro punti $(0, 0)$, $(1, 0)$, $(0, 1)$, $(1, 1)$ con etichetta di uscita 0, 1, 1, 0 non possono essere separati da una singola frontiera lineare. Un percettrone (che produce solo confini di decisione lineari) non riesce quindi a risolverlo.

Dimostrazione della non-linearità dello XOR. Assumendo la tabella di verità dello XOR e un percettrone con pesi v_1, v_2 e soglia v_0 , le condizioni di attivazione diventano




Figura 2.4: Schema del problema XOR: i vertici $(0,1)$ e $(1,0)$ appartengono alla classe 1, $(0,0)$ e $(1,1)$ alla classe 0. Nessuna frontiera lineare può separare le classi; è necessaria una frontiera non lineare (ottenibile con uno strato nascosto).

$$1 \cdot v_1 + 0 \cdot v_2 > v_0,$$

$$1 \cdot v_1 + 1 \cdot v_2 < v_0,$$

$$0 \cdot v_1 + 1 \cdot v_2 > v_0,$$

$$0 \cdot v_1 + 0 \cdot v_2 < v_0.$$

Da cui si ottiene

$$2v_0 < v_1 + v_2 < v_0,$$

ovvero una contraddizione: non esiste configurazione dei parametri di un singolo perceptrone che risolva XOR.

Rete di perceptroni. La soluzione consiste nell'usare una *rete di perceptroni* (uno strato nascosto) che trasformi lo spazio in modo da rendere il problema linearmente separabile all'uscita.


Un esempio minimale è:

$$f_1(x_1, x_2) = [x_1 - x_2 \geq 0.5],$$

$$f_2(x_1, x_2) = [x_2 - x_1 \geq 0.5],$$

$$f_3(f_1, f_2) = [1 \cdot f_1 + 1 \cdot f_2 \geq 0.5],$$

dove $[\cdot]$ indica una funzione soglia (vale 1 se la condizione è vera, 0 altrimenti). Le funzioni f_1 e f_2 realizzano una trasformazione non lineare degli input; nello spazio così trasformato l'uscita f_3 è ottenuta tramite una semplice soglia lineare.

Figura 2.5: Rete di percettroni per computare lo *XOR*

Infine, sebbene reti di percettroni possano risolvere *XOR*, l'algoritmo di apprendimento del singolo percettrone non è direttamente applicabile a reti multistrato; storicamente ciò contribuì al primo *AI winter* e la situazione migliorò con la formalizzazione della *retropropagazione* (*backpropagation*).

Riferimenti

Il materiale visto per questo capitolo comprende:

- Materiale visto a lezione.
- Note del prof. Antonino Furnari.
- Materiale sul percettrone dal libro *Neural Networks: A Systematic Introduction* [3].

Capitolo 3

Regressione

Definiamo il compito di regressione in termini di come un algoritmo elabora un esempio di input e produce un valore (o vettore) reale di output. Formalmente, vogliamo apprendere una funzione

$$h_{\vartheta} : \mathbb{R}^{d_1} \rightarrow \mathbb{R}^{d_2}, \quad d_1 \geq 1, d_2 \geq 1,$$

a partire da un dataset supervisionato

$$D = \{(x^{(i)}, y^{(i)})\}_{i=1}^m, \quad x^{(i)} \in \mathbb{R}^{d_1}, y^{(i)} \in \mathbb{R}^{d_2}.$$

In altre parole, individuare una funzione nello spazio dei dati, passante per tutti i valori del dataset in input, e presumibilmente capace di predire il valore associato ai dati di testing. Permette quindi di **stabilire relazioni tra i dati, individuare trend** e fare predizioni.

3.1 Ingredienti del task

- **Task:** predire valori reali a partire da input reali.
- **Modello:** ipotesi parametrica h_{ϑ} che mappa input in output.
- **Dati:** coppie etichettate $(x^{(i)}, y^{(i)})$.
- **Algoritmo di learning:** metodo per stimare ϑ (ottimizzazione).
- **Funzione di loss:** misura lo scarto tra predizioni e target.
- **Valutazione:** metriche su validation/test per giudicare il modello.

3.1.1 Tipi di regressione

1. **Regressione lineare**, $h_{\vartheta} : \mathbb{R} \rightarrow \mathbb{R}$, da spazio a una dimensione a una dimensione.
2. **Multiple regression**, $h_{\vartheta} : \mathbb{R}^{d_1} \rightarrow \mathbb{R}$, $d_1 > 1$, con d_1 features di input e un output.
3. **Multivariate regression**, $h_{\vartheta} : \mathbb{R}^{d_1} \rightarrow \mathbb{R}^{d_2}$, $d_1, d_2 > 1$, con d_1 features di input e d_2 output. Un modello di multivariate regression, viene allenato come un modello di multiple regression su ciascuno degli output.

3.2 Regressione lineare semplice

Nel caso $d_1 = d_2 = 1$ modelliamo la relazione tra un singolo ingresso $x \in \mathbb{R}$ e un'uscita reale $y \in \mathbb{R}$ con una retta:

$$h_{\vartheta}(x) = \vartheta_0 + \vartheta_1 x,$$

dove ϑ_0 è l'intercetta e ϑ_1 la pendenza. “Imparare” significa scegliere $\vartheta = (\vartheta_0, \vartheta_1)$ in modo che le predizioni siano vicine ai corrispondenti target.

3.2.1 Funzione di loss

Misuriamo la qualità della retta con l'errore medio quadratico (MSE):

$$J(\vartheta) = \frac{1}{2m} \sum_{i=1}^m (h_{\vartheta}(x^{(i)}) - y^{(i)})^2.$$

Il fattore $1/2$ è una costante di comodo che semplifica le derivate; il quadrato rende positivi tutti i contributi ed enfatizza gli errori grandi. In regressione lineare J è convessa rispetto ai parametri, quindi il minimo è unico (se c'è variabilità negli $x^{(i)}$). Otteniamo un grafico a tazza.

3.3 Regressione lineare multipla

Estendiamo al caso con più variabili in ingresso. Dato il vettore $x = (x_1, \dots, x_n)$, usiamo un parametro per ogni dimensione più il bias:

$$f(x) = \vartheta_0 + \vartheta_1 x_1 + \vartheta_2 x_2 + \dots + \vartheta_n x_n.$$

Per semplicità poniamo $x_0 = 1$ e definiamo il vettore esteso $x = (x_0, x_1, \dots, x_n)^{\top}$; allora

$$f(x) = \sum_{i=0}^n \vartheta_i x_i = \boldsymbol{\vartheta}^{\top} x.$$

Questo modello è, in sostanza, un *perceptrone senza soglia*: la combinazione lineare $\boldsymbol{\vartheta}^{\top} x$ è l'uscita continua del regressore.

3.4 Feature scaling

Per far funzionare bene (e in fretta) la discesa del gradiente, le feature vanno portate su scale simili. Due opzioni comuni:

$$\text{z-scoring: } x_j \leftarrow \frac{x_j - \mu_j}{\sigma_j}, \quad \text{min-max: } x_j \leftarrow \frac{x_j - x_j^{\min}}{x_j^{\max} - x_j^{\min}}.$$

Le statistiche $(\mu_j, \sigma_j, x_j^{\min}, x_j^{\max})$ si calcolano solo sul training e si riusano (senza ricalcolarle) su validation/test, per evitare data leakage.

3.5 Algoritmo di discesa del gradiente

L'obiettivo è scegliere ϑ che minimizza $J(\vartheta)$ funzione di loss. La *discesa del gradiente* è un metodo iterativo che aggiorna i parametri nella direzione di massima diminuzione di J . Nel prossimo esempio a due parametri $(\vartheta_0, \vartheta_1)$, supporremo l'intercetta $\vartheta_0 = 0$.

3.5.1 Idea dell'algoritmo

Partiremo da dei valori casuali dei parametri, in questo caso ϑ_1 , in quanto ϑ_0 è già fissata a 0 per semplicità. Osserveremo il coefficiente angolare della retta tangente alla funzione di loss, ossia la sua derivata. Quando questa è:

- negativa, incrementare il valore.
- positiva, decrementare il valore,

Il numero di iterazioni da ripetere dipende dalla convergenza che si vuole ottenere.

3.5.2 Algoritmo generale

Sia $X \in \mathbb{R}^{m \times (n+1)}$ la design matrix con prima colonna di 1, $y \in \mathbb{R}^m$ il vettore dei target e $\hat{y} = X\vartheta$ le predizioni. La loss è

$$J(\vartheta) = \frac{1}{2m} \|X\vartheta - y\|_2^2, \quad \nabla_{\vartheta} J(\vartheta) = \frac{1}{m} X^\top (X\vartheta - y).$$

Pseudocodice.

1. **Inizializza** in modo casuale: $\vartheta^{(0)} = (\vartheta_0, \dots, \vartheta_n)^\top$.
2. **Calcola le derivate parziali:**

$$\frac{\partial J(\vartheta)}{\partial \vartheta_j} = \frac{1}{m} \sum_{i=1}^m (\vartheta^\top \tilde{x}^{(i)} - y^{(i)}) \tilde{x}_j^{(i)}, \quad j = 0, \dots, n,$$

dove $\tilde{x}^{(i)} = (1, x_1^{(i)}, \dots, x_n^{(i)})^\top$.

3. **Aggiorna** i parametri (passo di ampiezza $\alpha > 0$):

$$\vartheta_j \leftarrow \vartheta_j - \alpha \frac{\partial J(\vartheta)}{\partial \vartheta_j}, \quad j = 0, \dots, n.$$

4. **Ripeti** i passi 2–3 finché non è soddisfatto un criterio d'arresto (iterazioni massime, $\|\nabla J(\vartheta)\|$ sotto soglia, variazione di J piccola).

In forma compatta: $\vartheta \leftarrow \vartheta - \frac{\alpha}{m} X^\top (X\vartheta - y)$.

3.6 Regressione polinomiale e feature mapping

Parlando della rete di perceptron per computare lo *XOR*, abbiamo già anticipato l'utilizzo di trasformazioni per semplificare spazi di partenza non linearmente separabili, col fine ultimo di renderli compatibili a modelli con parametri di tipo lineare. Indichiamo la trasformazione con $\Phi(x) \rightarrow (x')$. Il nostro modello lavorerà su $h_{\vartheta}(\Phi(x))$. Prendiamo come esempio la seguente trasformazione, che ci fa passare da uno spazio a 2 dimensioni, ad uno a 5 dimensioni.

$$\phi \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \rightsquigarrow \begin{pmatrix} x_1 \\ x_2 \\ x_1^2 \\ x_2^2 \\ x_1 x_2 \end{pmatrix}$$

Ottenendo un polinomio non lineare rispetto alle features, ma lineare rispetto ai parametri.

$$\vartheta_0 + \vartheta_1 x_1 + \vartheta_2 x_2 + \vartheta_3 x_1^2 + \vartheta_4 x_2^2 + \vartheta_5 x_1 x_2$$

3.7 Regolarizzazione

Per ridurre l'overfitting penalizziamo pesi grandi. In **Ridge** (L2) la loss è

$$J_{\lambda}(\vartheta) = \frac{1}{2m} \|X\vartheta - y\|_2^2 + \frac{\lambda}{2m} + \underbrace{\sum_{j=1}^n \vartheta_j^2}_{\text{Termine di regolarizzazione}},$$

dove tipicamente ϑ_0 non si penalizza. Aggiornamenti:

$$\vartheta_0 \leftarrow \vartheta_0 - \alpha \frac{1}{m} \sum_{i=1}^m (\hat{y}^{(i)} - y^{(i)}), \quad \vartheta_j \leftarrow \vartheta_j - \alpha \left[\frac{1}{m} \sum_{i=1}^m (\hat{y}^{(i)} - y^{(i)}) \tilde{x}_j^{(i)} + \frac{\lambda}{m} \vartheta_j \right] \quad (j \geq 1).$$

3.8 Valutazione

Metriche tipiche:

$$\text{MSE} = \frac{1}{m} \sum_{i=1}^m (\hat{y}^{(i)} - y^{(i)})^2, \quad \text{RMSE} = \sqrt{\text{MSE}}, \quad \text{MAE} = \frac{1}{m} \sum_{i=1}^m |\hat{y}^{(i)} - y^{(i)}|.$$

R^2 (coefficiente di determinazione):

$$R^2 = 1 - \frac{\sum_i (y^{(i)} - \hat{y}^{(i)})^2}{\sum_i (y^{(i)} - \bar{y})^2}.$$

3.8.1 REC curve

Ordinando gli errori assoluti $e_i = |\hat{y}^{(i)} - y^{(i)}|$ e tracciando, al variare di ε , la frazione cumulativa di esempi con errore $\leq \varepsilon$, si ottiene una curva di facilissima lettura; un'area sotto la curva¹ maggiore indica in genere prestazioni migliori. Analogamente, un'area sopra la curva² maggiore indica maggiore errore atteso. Quanto più velocemente cresce la curva, tanto più il modello dovrebbe essere accurato.




Figura 3.1: Esempio di curva REC.

Riferimenti

Il materiale per questo capitolo comprende:

- Materiale visto a lezione.
- Note del prof. Antonino Furnari.

¹AUC, area under the curve

²AOC, area over the curve

Capitolo 4

Classificazione

4.1 Introduzione alla classificazione

La **classificazione** è un altro dei problemi tipici che può essere risolto tramite un algoritmo di Machine Learning. Riguarda lo **stabilire se un dato input appartiene ad una tra delle classi** prestabilite dal problema. Il **target non sarà più un valore $\in \mathbb{R}$** , ma una tra k classi. Per studiare la classificazione, andremo a stabilire i requisiti e i nostri obiettivi.

- Un modello ben definito.
- Una funzione di loss per stabilire lo scarto con i risultati attesi.
- Un algoritmo di learning per trovare i parametri.
- Delle misure di valutazione.
- Niente overfitting!

4.1.1 Classificazione: binaria e di classe

Identifichiamo due tipi di task di classificazione:

- **Classificazione binaria.**
Le etichette $y \in \{0, 1\}$. Va associata ad x una delle due etichette, o le probabilità relative a ciascuna delle due.
- **Classificazione di classe.**
Le etichette $y \in \{0, 1, \dots, k-1\}$. Va associata ad x una delle etichette, o la probabilità relativa a ciascuna di esse.

È fondamentale sottolineare l'importanza che gli output di questi algoritmi siano sempre $\in [0, 1]$, in quanto da interpretare come **probabilità**.

4.2 Classificazione binaria

Nonostante i classificatori binari possano sembrare limitati, questi trovano applicazioni in vari task: solitamente, questi si basano sulla suddivisione di immagini più grandi in *patches* più piccole, con una successiva, appunto, classificazione, per individuare determinati


elementi. Nel **medical imaging**, i classificatori binari possono individuare piccoli tumori. Nei **controlli qualità** in ambito industriale, possono individuare **imperfezioni** nei materiali. Nel campo più generale della **computer vision**, gli algoritmi di classificazione (binaria e non) sono fondamentali.

4.2.1 Perché non usare la regressione lineare per la classificazione?


Si potrebbe pensare di **usare un modello di regressione lineare per effettuare classificazione binaria**, e l'intuizione non sarebbe nemmeno totalmente sbagliata: potremmo usare, ad esempio, la regressione per **trovare una retta che unisce i dati** in maniera opportuna, e in funzione della pendenza di questa retta, **stabilire un valore di sogliatura** per distinguere due classi.

Forniamo il seguente esempio: vogliamo addestrare un modello per prevedere se un tumore è benigno o maligno usando una singola feature (dimensione del tumore).

Usiamo la regressione lineare e facciamo il fitting di una retta nello spazio (troviamo la retta, cioè la funzione che meglio si posiziona a media tra tutti i punti). Possiamo trovare il miglior $y = \vartheta^T x$ dal nostro set di dati e quindi selezionare una **soglia** su y per classificare quando il tumore è maligno o meno: $h_{\vartheta}(x) \leq 0.5 \rightarrow 0$, $h_{\vartheta}(x) \geq 0.5 \rightarrow 1$.



Ci sono **due criticità** relative all'utilizzo della regressione. La prima, riguarda la versatilità del modello: il fitting della retta non è opportuno, in quanto la regressione lineare dipende fortemente dalla distribuzione dei dati.



La seconda criticità riguarda invece la y , non sempre limitata tra 0 e 1, come ci aspettiamo in un modello di classificazione binaria. Come ci comportiamo con valori più grandi di 1? E con valori minori di 0? Possiamo risolvere il problema introducendo delle funzioni, dette funzioni **di linking**. Queste ci permettono di **adattare i nostri valori** a modelli di regressione che altrimenti non sarebbero opportuni per la classificazione. Vediamo un esempio relativo alla regressione logistica usando la funzione **sigmoide**.

4.3 Regressione logistica - Sigmoide

Se la regressione lineare restituisce una y non limitata tra 0 e 1, la **regressione logistica** risolve il problema con una funzione, detta **sigmoide**, applicata sul risultato $z = \vartheta^T X$ del modello di regressione. La **sigmoide** è una funzione del tipo


$$\bar{\sigma}(z) = \frac{1}{1 + e^{-z}} = \frac{1}{1 + e^{-\vartheta^T X}}$$

con $z = \vartheta_0 + \vartheta_1 x_1 + \dots + \vartheta_i x_i$. Questa funzione ha un'interpretazione probabilistica molto banale, opportuna per **adattare i modelli di regressione lineare su problemi di classificazione**¹. Osserviamo che:

- $1 - \bar{\sigma} = \sigma(z)$
- $\frac{\partial \bar{\sigma}(z)}{\partial z} = \bar{\sigma}(z)(1 - \bar{\sigma}(z)) = \bar{\sigma}(z)\sigma(-z)$
- È inoltre dimostrabile che $\bar{\sigma} = \frac{1}{2} + \frac{1}{2} \tanh\left(\frac{z}{2}\right)$. Questo ci apre le porte a implementazioni molto più semplici.

Concludiamo che la regressione logistica, è ottimale per trovare opportuni parametri di ϑ^T , che moltiplicati a x , ci permetteranno di stabilire il **decision boundary**, nella ben nota forma:

$$\vartheta_0 x_0 + \vartheta_1 x_1 + \vartheta_2 x_2 + \dots \vartheta_d x_d$$



¹Non si può pretendere di usare un modello di regressione lineare su task di classificazione, senza fare alcun tipo di modifica, come quelle che introduciamo con la sigmoide.

4.3.1 Vantaggi relativi all'uso della sigmoide

- Interpretazione probabilistica semplice. Da valori $\in [0, 1]$.
- Derivabile, più liscia rispetto ad una step function.
- Introduce non linearità, migliorando la classificazione.


4.4 Funzione di Loss

Avere una funzione di Loss associata al modello è fondamentale per capire come effettuare il training, e quali sono i migliori parametri di ϑ^T per la classificazione. Per modellare questa funzione (da minimizzare secondo l'algoritmo di discesa del gradiente), utilizzeremo due funzioni logaritmiche. La funzione di Loss sarà definita in funzione dell'etichetta $\hat{y}$.

$$\text{Loss}(h_{\vartheta}(x), y) = \begin{cases} -\log(h_{\vartheta}(x)) & \text{se } \hat{y} = 1 \\ -\log(1 - h_{\vartheta}(x)) & \text{se } \hat{y} = 0 \end{cases}$$

Questo, perché l'errore deve essere 1 quando $\hat{y} = 0$ e $y = 1$, o quando $\hat{y} = 1$ e $y = 0$.

Ai fini della semplicità e univocità della spiegazione, useremo y per indicare ciò che fino ad ora abbiamo indicato con $\hat{y}$.



Possiamo esprimere la funzione di Loss anche in questo modo, rendendo unica la definizione della funzione.

$$\text{Loss}(h_{\vartheta}(x), y) = -[y \log(h_{\vartheta}(x)) + (1 - y) \log(1 - h_{\vartheta}(x))]$$

Definita la funzione di Loss, andremo a definire la funzione di costo

$$J(\vartheta) = -\frac{1}{m} \sum_{i=1}^m (y^{(i)} \log(h_{\vartheta}(x)) + (1 - y^{(i)}) \log(1 - h_{\vartheta}(x)))$$

su cui sarà possibile applicare l'algoritmo di discesa del gradiente, fino alla convergenza del modello.

$$\vartheta_j^{\text{new}} = \vartheta_j^{\text{old}} - \alpha \frac{\partial J(\vartheta)}{\partial \vartheta_j} \quad \forall j$$

4.4.1 Derivata parziale della funzione di costo

Necessaria per applicare la discesa del gradiente.

$$\frac{\partial J(\vartheta)}{\partial \vartheta_j} = \frac{1}{m} \sum_{i=1}^m \underbrace{(h_{\vartheta}(x^{(i)}) - y^{(i)})}_{(*)} x_j^{(i)} \quad \forall j = 0, \dots, d$$

(*) Questo membro nasconde la funzione sigmoide $\bar{\sigma}(\vartheta^T X^{(i)})$.

4.4.2 Entropia dell'informazione

La loss function di questo modello presenta un'interpretazione probabilistica basata sul concetto di **entropia** dell'informazione. Parleremo quindi **Binary Cross Entropy Loss**. La seguente, è la formula dell'entropia:


$$H(X) = - \sum_{k=1}^K p_k \log_2(p_k)$$

con p_k probabilità di essere di classe k . La distribuzione di probabilità (e quindi l'entropia). Queste distribuzioni informazioni su:

- Incertezza.
- Misura del disordine dalle classi.
- Quanto la probabilità è concentrata su una classe.
- Informazione (la distribuzione è molto informativa se è capace di distinguere in maniera opportuna).

Un esempio su $k = 2$ è la funzione


$$H(X) = -p_1 \log_2(p_1) - p_2 \log_2(p_2) = -[p_1 \log_2(p_1) + p_2 \log_2(p_2)]$$



$\log_2(0)$ è indefinito. Quando facciamo calcoli relativi alla cross-entropy, consideriamo valori piccoli, mai nulli. In questo esempio e nel prossimo esercizio, quando utilizziamo 0, stiamo approssimando un valore molto piccolo, ma mai effettivamente nullo. Inoltre, in un modello reale, avere una $p_k = 0$ o $p_k = 1$ significa probabile overfitting del modello.

4.4.2.1 Esercizio sull'entropia

Riordina le seguenti distribuzioni in ordine crescente di entropia.



$$H(X) = -p_1 \log_2(p_1) - p_2 \log_2(p_2) = -[p_1 \log_2(p_1) + p_2 \log_2(p_2) + p_3 \log_2(p_3)]$$

1. $H(X_1) = -[0 \log(0) + 1 \log(1) + 0 \log(0)] = 0$
2. $H(X_2) = -[1 \log(1) + 0 \log(0) + 0 \log(0)] = 0$
3. $H(X_3) = -[0,33 \log(0,33) + 0,33 \log(0,33) + 0,33 \log(0,33)] \approx 1,5848$
4. $H(X_4) = -[0,80 \log(0,80) + 0,20 \log(0,20) + 0 \log(0)] \approx 0,722$


$$X_1 = X_2 < X_4 < X_3$$

4.4.3 Binary Cross Entropy Loss

La seguente formula è equivalente alla nostra funzione di Loss, ma fornisce un'interpretazione più intuitiva. Definiamo la **Binary Cross Entropy Loss** come:

$$H_{BCE}(X) = \frac{1}{m} \sum_{i=1}^m \left(- \sum_{k=1}^K \underbrace{p_k^{(i)}}_{(a)} \log_2 \left(\underbrace{q_k^{(i)}}_{(b)} \right) \right)$$


Dove (a) è la distribuzione vera della classificazione, detta **ground truth**, ovvero quella con probabilità massima sulla classe attesa, mentre (b) è la distribuzione data dal classificatore. Misura quindi la **distanza tra le due distribuzioni**. Minimizzare $H_{BCE}(X)$, significherà rendere le distribuzioni ideali e quelle effettive del classificatore, quanto più simili possibile.



4.5 Overfitting nella classificazione

Rischiamo di cadere in overfitting nell'utilizzo di classificatori polinomiali. Basterà usare i termini di regolarizzazione per diminuire o annullare l'impatto di alcuni termini di grado eccessivamente alto, ottenendo così:

$$J(\vartheta) = -\frac{1}{m} \sum_{i=1}^m (y^{(i)} \log(h_{\vartheta}(x)) + (1 - y^{(i)}) \log(1 - h_{\vartheta}(x))) + \frac{\lambda}{2m} \sum_{j=1}^n \vartheta_j^2$$



4.6 Reject Region, regione d'incertezza

Sia nella classificazione binaria, che in quella multiclasse, è possibile osservare casi in cui la probabilità stimata che un input appartenga ad una tra le classi specificate, non superi un determinato valore di certezza. Sono dei casi limite che vanno gestiti in maniera opportuna:

1. Prendere il valore con certezza più alta, se è proprio obbligatorio stabilire una classe, e il task non è particolarmente delicato.
2. Scartare l'input. Un'opzione migliore in campi più delicati, come quello medico.




Figura 4.1: La zona d'incertezza (in cui $P(C_1|x) \sim P(C_2|x)$)

4.7 Classificazione multiclasse, approccio naive OVA e OVO


La classificazione multiclasse si distingue da quella binaria per il numero di classi. Il dataset di input non avrà più etichette binarie, ma k etichette. A ogni classe si associa un numero, ai fini di semplicità.

4.7.1 Metodo One vs All

Possiamo ottenere una classificazione multiclasse da dei classificatori binari, usando la metodologia **one vs all**. Immaginiamo di avere un sistema di classificazione figure geometriche, con le classi *triangolo*, *quadrato* e *cerchio* (c_1, c_2, c_3). Avremo bisogno di tre classificatori, $h_{\theta}^1, h_{\theta}^2, h_{\theta}^3$, capaci di misurare $P(\text{triangolo}|x)$, $P(\text{quadrato}|x)$, $P(\text{cerchio}|x)$. Prenderemo poi l'etichetta associata al valore di probabilità più alto

$$\hat{k} = \arg \max_k h_{\theta}^k(\bar{x})$$

ottenendo effettivamente una classificazione multiclasse.



Il training è effettuato sui singoli classificatori binari. Osserviamo inoltre che, con k classi:

$$\text{Numero di classificatori richiesti in one vs all} = k$$

4.7.2 Metodo One vs One


In questo caso, i classificatori distinguono classi a due a due. Si fanno poi le opportune valutazioni per capire quale classe assegnare. Il numero di classificatori risulta essere più alto. Con k classi abbiamo:

$$\text{Numero di classificatori richiesti in one vs one} = \frac{k(k-1)}{2}$$

Immaginiamo un classificatore per lo stesso problema precedentemente esposto: otteniamo le classi (c_1, c_2, c_3). Questi classificatori su coppie, daranno poi dei risultati. La classe più votata vince:


$$c_1 \text{ vs } c_2, \quad c_2 \text{ vs } c_3, \quad c_1 \text{ vs } c_3$$

One-vs-one



4.7.3 Confronto tra *One vs All* e *One vs One*

Il modello one vs one, per quanto più oneroso in termini di numero di classificatori binari richiesti, non presenta l'area di incertezza su tutte le classi, che invece possiamo trovare nel classificatore one vs all.



4.8 Stochastic Gradient Descent

L'algoritmo di discesa del gradiente, computa $J(\vartheta)$ su **tutti** i campioni del training set: associando al numero di campioni il valore m , a d il numero di feature e ad e le epoche di training, otteniamo un numero di operazioni complessive pari a

$$m \times d \times e$$

Questo prodotto raggiunge facilmente valori molto alti. Un modo per ridurre il numero di operazioni, senza intaccare il risultato del training, e arrivare a convergenza, è l'uso della **SGD**, ossia della **discesa del gradiente stocastica**. Ad ogni iterazione del training si campiona un mini-**batch** di campioni di dimensione $b \leq m$. Questo campione è scelto randomicamente a ogni iterazione.

$$b \times d \times e$$

L'algoritmo deve arrivare a convergenza: se non arriva a convergenza, si ripete il campionamento e si ripete il training.

4.9 Softmax - Classificazione Multiclasse

Abbiamo quindi visto com'è possibile implementare un classificatore multiclasse utilizzando più classificatori binari. Tuttavia, questa strategia (a prescindere da OVA e OVO) presenta delle criticità:

- Numero di classificatori elevato, che porta a tempi di training lunghi.
- Possibili aree di incertezza.
- Difficoltà nell'interpretare le probabilità restituite dai classificatori.

Si può ovviare a questi problemi con il modello **Softmax**, che estende la regressione logistica alla classificazione multiclasse.

4.9.1 Definizione

Sia K il numero di classi da prevedere. Il modello Softmax restituisce un vettore $P_{\vartheta}^{(k)}$ di lunghezza K , in cui ogni elemento $P_{\vartheta}^{(i)}$ rappresenta la **probabilità** che l'input x appartenga alla classe i . L'obiettivo è quindi, cercare di **stimare**:

$$P_{\vartheta}^{(k)}(y = k|x) \quad \forall k \in \{1, \dots, K\}$$

la somma di ogni elemento del vettore, è sempre $= 1$.

4.9.2 Funzione Softmax

Partiamo dall'idea che il softmax restituisce un vettore di probabilità:

$$h_{\vartheta}^{(c)}(x) = \begin{pmatrix} P_{\vartheta}^{(1)}(y = 1|x) \\ P_{\vartheta}^{(2)}(y = 2|x) \\ \vdots \\ P_{\vartheta}^{(K)}(y = K|x) \end{pmatrix} = \underbrace{\frac{1}{\sum_{k=0}^{K-1} e^{\vartheta^{(k)T}x}}}_{\text{Normalizzatore della distribuzione}} \cdot \begin{pmatrix} e^{\vartheta^{(1)T}x} \\ e^{\vartheta^{(2)T}x} \\ \vdots \\ e^{\vartheta^{(K)T}x} \end{pmatrix} = \frac{e^{\vartheta^{(c)T}x}}{\sum_{k=0}^{K-1} e^{\vartheta^{(k)T}x}}$$

Dove c è la classe di cui vogliamo calcolare la probabilità, k è l'indice che scorre tutte le classi, e $\vartheta^{(k)}$ è il vettore dei parametri associati alla classe k .

N.B. Ogni classe k ha il proprio vettore di parametri $\vartheta^{(k)}$ (i pesi del modello). Inoltre, una volta finito il learning del modello, la somma delle probabilità restituite dal softmax sarà sempre pari a 1 ($\sum_{k=1}^K P_{\vartheta}^{(k)}(y = k|x) = 1$).

4.9.3 Funzione di Costo

La funzione di costo del softmax è una funzione chiamata Cross Entropy Loss. Prima di poter definire la funzione di costo, definiamo una variabile ausiliaria $1\{\text{proposizione}\}$ che vale 1 se la proposizione è vera, 0 altrimenti. La funzione di costo del softmax è quindi:

$$J(\vartheta) = -\frac{1}{m} \left[\sum_{i=1}^m \sum_{c=1}^K 1\{y^{(i)} = c\} \log P_{\vartheta}^{(c)}(y = c|x^{(i)}) \right] + \underbrace{\frac{\lambda}{2} \sum_{c=1}^K \sum_{j=1}^n (\vartheta_j^{(c)})^2}_{\text{Termine di regolarizzazione}}$$

Dove il termine di regolarizzazione serve a prevenire l'overfitting del modello.

4.9.4 Obiettivo di Learning

L'obiettivo di learning è quello di minimizzare la funzione di costo, trovando i parametri ottimali ϑ :

$$\vartheta = \arg \min_{\vartheta} J(\vartheta)$$

Ovvero, trovare i parametri che minimizzano la distanza tra la distribuzione di probabilità predetta dal modello e la distribuzione di probabilità reale (ground truth).

Per fare questo possiamo usare la discesa del gradiente, per cui abbiamo bisogno della derivata parziale della funzione di costo rispetto ai parametri $\vartheta_j^{(c)}$:

$$\frac{\partial J(\vartheta)}{\partial \vartheta_j^{(c)}} = -\frac{1}{m} \sum_{i=1}^m \left[\left(1\{y^{(i)} = c\} - P_{\vartheta}^{(c)}(y = c|x^{(i)}) \right) x_j^{(i)} \right] + \underbrace{\lambda \vartheta_j^{(c)}}_{\text{Termine di regolarizzazione}}$$

E da questa, aggiorniamo i pesi $\vartheta_j^{(c)}$ utilizzando la regola di aggiornamento della discesa del gradiente:

$$\vartheta_j^{(c)} \leftarrow \vartheta_j^{(c)} - \alpha \frac{\partial J(\vartheta)}{\partial \vartheta_j^{(c)}}, \quad \forall j \in [0, n], \quad \forall c \in [0, K-1]$$

4.9.5 Proprietà del Softmax

Il modello softmax è **overparametrizzato**: per ogni ipotesi che potrebbe essere fatta sui dati, esistono infinite combinazioni di parametri che a partire dal vettore di feature $X \in \mathbb{R}^n$ producono la stessa predizione nel vettore di probabilità Y .

Per dimostrarlo, partiamo da:

$$\begin{aligned}
 h_{\vartheta}^{(c)}(x) &= \frac{e^{\vartheta^{(c)\top} x}}{\sum_{k=0}^{K-1} e^{\vartheta^{(k)\top} x}} && \text{Formula del Softmax} \\
 &= \frac{e^{(\vartheta^{(c)} - \psi)^{\top} x}}{\sum_{k=0}^{K-1} e^{(\vartheta^{(k)} - \psi)^{\top} x}} && \text{Sottraiamo lo stesso } \psi \\
 &= \frac{e^{\vartheta^{(c)\top} x} e^{-\psi^{\top} x}}{\sum_{k=0}^{K-1} e^{\vartheta^{(k)\top} x} e^{-\psi^{\top} x}} && \text{Separiamo gli esponenziali} \\
 &= \frac{e^{\vartheta^{(c)\top} x}}{\sum_{k=0}^{K-1} e^{\vartheta^{(k)\top} x}} && \text{Si cancella il fattore comune } e^{-\psi^{\top} x}
 \end{aligned}$$

Dove $\psi \in \mathbb{R}^n$ è un vettore arbitrario. Quindi, sottraendo lo stesso vettore ψ da tutti i vettori di parametri $\vartheta^{(k)}$, otteniamo gli stessi valori di probabilità predetti dal modello, perciò esistono infinite combinazioni di parametri che producono la stessa predizione.

Nota. Può essere trovato un approfondimento di questa parte nell'appendice A alla sezione A.2.

4.9.6 Rete neurale Softmax

Il softmax può essere visto come un particolare tipo di rete neurale:




Figura 4.2: Flusso della regressione softmax con due ingressi e tre classi: dai logit $z_i = w_{i,1}x_1 + w_{i,2}x_2 + b_i$ alle probabilità $a_i = \frac{e^{z_i}}{\sum_{k=1}^3 e^{z_k}}$, fino alla loss a entropia incrociata $L = \sum_{j=1}^3 -y_j \log(a_j)$.

4.9.7 Funzione di Loss

La funzione di Loss usata nel softmax normalmente è una variante di **cross entropy loss** (molto simile alla funzione di costo). Si possono usare alternative, in particolare la **Hinge Loss** trasforma la classificazione multiclasse in un problema di massimizzazione del

margin tra le classi, come nelle SVM. La Hinge Loss è definita come:

$$\text{Loss}(h_{\vartheta}(x), y) = \sum_{i \neq y} \max(0, h_{\vartheta}(x)_i - h_{\vartheta}(x)_y + \Delta)$$

Riferimenti

Il materiale di questo capitolo comprende:

- Materiale visto a lezione.

Capitolo 5

Design, valutazione e scelta dei parametri di un algoritmo di ML

5.1 Momento e gradiente

Una variante dell'algoritmo di discesa del gradiente, ovvero **la discesa del gradiente con momento**, modifica la nostra formula del gradiente nel seguente modo:

$$\begin{aligned}\vartheta_j^{\text{new}} &\leftarrow \vartheta_j^{\text{old}} - \alpha z^{\text{new}} \\ z^{\text{new}} &\leftarrow \beta z^{\text{old}} + \frac{\partial J(\vartheta^{\text{old}})}{\partial \vartheta^{\text{old}}}\end{aligned}$$

l'idea è quella di mantenere in z una **media dei gradienti recenti**, in modo da mantenere coerenza durante la convergenza: valori incoerenti del gradiente sono **rumore**, e questo **può causare zig-zag e rallentamenti nella convergenza**. Tenendo uno storico dei valori del gradiente (usando il **momentum** β come parametro che stabilisce l'influenza dei vecchi valori su quelli nuovi), diventa possibile **annullare parzialmente o totalmente l'effetto del rumore**. Accelera anche la convergenza stessa, **rinforzando i passi coerenti**. Si accorcia quindi il training, e si migliorano le performance a parità di epoche. Osservazioni statistiche consigliano l'utilizzo di $\beta = 0.90$ per ottenere risultati migliori.

5.2 Design di Algoritmi

Progettare bene un algoritmo di ML permette di ottenere migliori risultati in meno tempo e con meno risorse computazionali. Si pensi al cercare di inserire a casaccio i parametri di un modello, senza una logica precisa: si rischia di perdere tempo, se invece si pensa a come variare i parametri in maniera sistematica, per capire l'impatto di ciascuno di essi sul modello si potrebbe ottenere un modello migliore in meno tempo.

5.2.1 Strategie di miglioramento

Supponiamo di aver implementato la regressione lineare con regolarizzazione, ma gli errori su nuovi campioni sono comunque troppo alti. Potremmo pensare ad alcune strategie per migliorare il modello:

Aumentare i campioni di Training. Non è sempre una scelta utile, anche perché se il modello non funziona su nuovi campioni significa che il problema (molto probabilmente) è di overfitting. Aumentare i campioni di training potrebbe aiutare, ma non è detto che lo faccia.

Ridurre il set di Features. Si potrebbe pensare di ridurre il numero di features in input al modello, in modo da semplificare il problema e ridurre il rischio di overfitting. Questa tecnica può essere efficace se alcune features sono ridondanti o non rilevanti per il task. Tuttavia, è importante fare attenzione a non eliminare informazioni utili.

Cercare nuove features. L'opposto della riduzione delle features: il problema è di underfitting, in quanto il modello non ha abbastanza informazioni per generalizzare bene. Aggiungere nuove features può aiutare a migliorare le prestazioni del modello ma richiede un'attenta selezione delle stesse per evitare di introdurre rumore.

Utilizzare features polinomiali. Trasformare le features esistenti in polinomiali può aiutare a catturare relazioni non lineari tra le variabili. Questa tecnica può essere utile se si sospetta che il modello lineare non sia sufficiente per rappresentare i dati. Tuttavia, l'aggiunta di termini polinomiali aumenta la complessità del modello e il rischio di overfitting, quindi è importante bilanciare questa scelta con tecniche di regolarizzazione.

Far variare il parametro di regolarizzazione λ . Modificare il parametro di regolarizzazione può influenzare significativamente le prestazioni del modello. Un valore più alto di λ penalizza maggiormente i pesi del modello, riducendo il rischio di overfitting, mentre un valore più basso consente al modello di adattarsi meglio ai dati di training, ma aumenta il rischio di overfitting. È importante trovare un equilibrio ottimale attraverso tecniche come la validazione incrociata (che vedremo più avanti).

Solitamente si cerca di effettuare test di diagnostica applicati al modello, per permettere di ottenere informazioni dettagliate su cosa funziona o non funziona con l'obiettivo di ottenere indicazioni per migliorare le prestazioni.

5.3 Valutazione

La valutazione di un algoritmo di ML è fondamentale per capire se il modello è adatto al task.

5.3.1 Valutazione incrociata

Un modo di fare valutazione incrociata¹ è la **grid search**, che sfrutta la k-Fold Cross Validation: si suddivide il dataset in t splits e in k folds, e si allena il modello su $t - 1$ splits e si valuta su uno split di validation, ripetendo il processo per tutti i t splits. In questo modo si ottengono t stime delle prestazioni del modello, che vengono poi mediate per ottenere una stima complessiva. Questo processo viene ripetuto per tutti i possibili set di iperparametri del modello, selezionando quelli che producono la *migliore prestazione* media sul validation set. Infine, si valuta il modello finale con gli iperparametri selezionati sul test set per ottenere una stima finale delle prestazioni del modello.

Procedura. La procedura è la seguente:

1. Si suddivide il dataset originale in training/validation set e un test set che non verrà usato fino alla fine della valutazione.
2. Si suddivide il dataset rimanente in t splits e in k folds.
3. Si seleziona uno split come validation set e gli altri $t - 1$ come training set.
4. Si allena il modello sui $t - 1$ training splits.
5. Si valuta il modello con una funzione J_{VAL} sul validation fold (non usato per il training).
6. Si ripete il processo per tutti i t splits, ottenendo t valori di J_{VAL} .
7. Si calcola la media dei t valori di J_{VAL} per ottenere una stima complessiva delle prestazioni del modello.
8. Si ripete l'intero processo per tutti i possibili set di iperparametri del modello.
9. Si selezionano gli iperparametri che hanno prodotto la migliore prestazione media sul validation set.
10. Infine, si valuta il modello finale con gli iperparametri selezionati sul test set per ottenere una stima finale delle prestazioni del modello.

In questo modo il modello è robusto perché è stato allenato su diversi training set per i dati, allenato sui validation set per gli iperparametri e testato su un test set **mai visto prima**.

Esempio. Ipotizziamo di avere un certo dataset, dividiamolo in un test set (20% dei dati) e in un training/validation set (80% dei dati). Definiamo le funzioni di costo:

- **Funzione di costo di training:**

$$J_{\text{TR}}(\vartheta) = \frac{1}{2m_{\text{TR}}} \sum_{i=1}^{m_{\text{TR}}} \left(h_{\vartheta}(x_{\text{TR}}^{(i)}) - y_{\text{TR}}^{(i)} \right)^2$$

¹Per valutazione incrociata si intende la tecnica di suddividere il dataset in più parti per allenare e testare il modello in modo iterativo, garantendo una stima più robusta delle prestazioni.

Dove m_{TR} è il numero di campioni nel training set, $x_{\text{TR}}^{(i)}$ e $y_{\text{TR}}^{(i)}$ sono rispettivamente l'input e l'output del i -esimo campione del training set.

- **Funzione di costo di validation:**

$$J_{\text{VAL}}(\vartheta) = \frac{1}{2m_{\text{VAL}}} \sum_{i=1}^{m_{\text{VAL}}} \left(h_{\vartheta}(x_{\text{VAL}}^{(i)}) - y_{\text{VAL}}^{(i)} \right)^2$$

Dove m_{VAL} è il numero di campioni nel validation set, $x_{\text{VAL}}^{(i)}$ e $y_{\text{VAL}}^{(i)}$ sono rispettivamente l'input e l'output del i -esimo campione del validation set.

- **Funzione di costo di test:**

$$J_{\text{TEST}}(\vartheta) = \frac{1}{2m_{\text{TEST}}} \sum_{i=1}^{m_{\text{TEST}}} \left(h_{\vartheta}(x_{\text{TEST}}^{(i)}) - y_{\text{TEST}}^{(i)} \right)^2$$

Dove m_{TEST} è il numero di campioni nel test set, $x_{\text{TEST}}^{(i)}$ e $y_{\text{TEST}}^{(i)}$ sono rispettivamente l'input e l'output del i -esimo campione del test set.

Supponiamo di voler utilizzare $t = 5$ splits e $k = 5$ folds. La suddivisione del training/validation set sarà la seguente:

	FOLD 1	FOLD 2	FOLD 3	FOLD 4	FOLD 5
SPLIT 1					
SPLIT 2					
SPLIT 3					
SPLIT 4					
SPLIT 5					

Figura 5.1: Dataset diviso in split e folds per la valutazione incrociata.

Dopo aver suddiviso i dati, ognuno dei dati produrrà una stima di $J_{\text{VAL}}^H(\vartheta^{(i)})$ per un certo i -esimo set valutata sull'iperparametro H . Da queste andiamo a fare la media:

$$\bar{J}_{\text{VAL}}^H(\vartheta) = \frac{1}{t} \sum_{i=1}^t J_{\text{VAL}}^H(\vartheta^{(i)})$$

Ottenuta la media $\bar{J}_{\text{VAL}}^H(\vartheta)$ per ogni set di iperparametri H , si seleziona quello che minimizza la funzione di costo media:

$$H^* = \arg \min_H \bar{J}_{\text{VAL}}^H(\vartheta)$$

Una volta fissato il miglior iperparametro H^* , si allena il modello sul test set per ottenere la stima finale:

$$J_{\text{TEST}}^{H^*}(\vartheta)$$

5.3.2 Bias e Varianza

Per valutare le prestazioni di un modello possiamo usare i valori del bias e della varianza per fare delle stime su come il modello si comporta sui dati.




Figura 5.2: Underfitting—capacità adeguata—overfitting in regressione polinomiale: punti blu = dati di training (TR), punti rossi = fuori da TR; la linea verde mostra il fit del modello: lineare (sinistra), polinomio di grado 2 (centro) e polinomio di grado 5 (destra).

Bias. Ricordiamo che il bias è l'**errore sistematico** che il modello commette sui dati. Un modello con alto bias tende a sottostimare la complessità del problema, portando a errori elevati sia sul training set che sul test set. Questo fenomeno è noto come **underfitting**. Nell'immagine 5.2, il grafico a sinistra mostra un esempio di underfitting, dove il modello lineare non riesce a catturare la relazione tra le variabili e commette un errore sistematico sia sul training set (punti blu) che sul test set (punti rossi).

Varianza. La varianza rappresenta la sensibilità del modello alle variazioni nei dati di training. Un modello con alta varianza tende a sovradattarsi ai dati di training, catturando il rumore invece della vera relazione tra le variabili. Questo porta a errori bassi sul training set ma elevati sul test set, fenomeno noto come **overfitting**.

Nella figura 5.2, il grafico a destra mostra un esempio di overfitting, dove il modello polinomiale è troppo complesso e si adatta troppo strettamente ai dati di training, risultando in prestazioni scadenti sui dati di test². Come si vede dall'immagine al centro della figura 5.2, un modello con capacità adeguata riesce a bilanciare bias e varianza, ottenendo buone prestazioni sia sul training set che sul test set. Per valutare e risolvere i problemi sul modello, possiamo andare a controllare come Bias e Varianza variano al variare dei parametri del modello³ e notiamo che si può costruire una correlazione tra l'errore commesso dal modello (quindi o in J_{TEST} o in J_{VAL}) e la complessità del polinomio (il grado):

²Si noti che basterebbe rimuovere un punto del training set per far cambiare completamente il modello, in quanto altamente sensibile ai dati di input.

³In quella che molti chiamano **bias-variance trade-off**.




Figura 5.3: Trade-off tra bias e varianza in funzione della complessità del modello.

Parametro di regolarizzazione. Anche i parametri di regolarizzazione, esattamente come il modello (i suoi parametri), devono essere stabiliti sperimentalmente. Si parte da $\lambda^0 = 0$, testando valori di $\lambda^{(1)}, \lambda^{(2)} \dots \lambda^{(k)}$ sempre più grandi, verificando come cambia $J_{\text{VAL}}(\vartheta^i)$ in funzione di λ^i :

$$\begin{bmatrix} \lambda^{(0)} \\ \lambda^{(1)} \\ \lambda^{(2)} \\ \lambda^{(3)} \\ \vdots \\ \lambda^{(k)} \end{bmatrix} \Rightarrow \min_{\vartheta} J(\vartheta) \Rightarrow \begin{bmatrix} \vartheta^{(0)} \\ \vartheta^{(1)} \\ \vdots \\ \vartheta^{(k)} \end{bmatrix} \Rightarrow \begin{bmatrix} J_{\text{VAL}}(\vartheta^{(0)}) \\ J_{\text{VAL}}(\vartheta^{(1)}) \\ \vdots \\ J_{\text{VAL}}(\vartheta^{(k)}) \end{bmatrix} \Rightarrow \underbrace{\text{BEST } J_{\text{VAL}}}_{\min} \Rightarrow J_{\text{TEST}}(\vartheta^{\text{BEST}})$$

In questo modo si riesce a trovare il miglior parametro di regolarizzazione che minimizza l'errore sul validation set, e si può usare questo parametro per valutare il modello sul test set.

Altre curve. Un'altra curva potrebbe essere quella che mostra l'**errore** su *train set* e *validation set* in funzione del numero di campioni di training (figura 5.4). In questo modo si può capire se il modello soffre di overfitting o underfitting:

La figura conferma il fatto che esiste il trade-off bias-varianza, in quanto:

- Se siamo in presenza di *high bias*, quindi un alto gap tra la curva di train e l'asse delle ascisse, aumentare il numero di dati di training non aiuta molto.
- Se siamo in presenza di *high variance*, quindi un grande gap tra l'errore commesso tra il training set e il validation set, aumentare il numero di dati di training potrebbe aiutare a migliorare i risultati (non sempre).




Figura 5.4: Learning curves: errore su training J_{TRAIN} e su validation J_{VAL} in funzione del numero di esempi m . J_{VAL} decresce, J_{TRAIN} cresce leggermente e il *generalization gap* (freccia) si riduce; le curve si avvicinano all'errore irreducibile.

Riferimenti

Il materiale di questa lezione comprende:

- Materiale visto a lezione.
- Presentazione del prof. Giovanni Farinella.

Capitolo 6

Introduzione alle reti neurali

Le reti neurali, grazie alla loro capacità di gestire dati non lineari e molto rumorosi, e di riconoscere pattern complessi, ritrovano moltissime applicazioni per la risoluzione di task di vario tipo. Esistono inoltre numerose varianti delle reti neurali (profonde e non), tra cui la MLP (di cui parleremo) e la CNN.

6.1 Definizione di rete neurale

Una rete neurale è una funzione matematica *annidata* del tipo:

$$f_n(f_{n-1}(\dots(f_1(x))))$$

dove n coincide col numero di strati, o *layer*. Questa rete neurale ritorna uno scalare y . Una rete neurale è quindi ottenuta da una **composizione di funzioni derivabili**. Le funzioni sono dette **funzioni di attivazione**, e andremo a vederne presto alcuni esempi.




Figura 6.1: Un multilayer perceptron, ossia una particolare rete neurale.

Gli strati si suddividono in:

- **Input Layer:** $a_0^{(1)}, a_1^{(1)}, \dots, a_n^{(1)}$. Ciascuno degli input viene moltiplicato per il rispettivo peso della coppia input-hidden layer. Questo viene realizzato tramite un prodotto righe per colonne tra la matrice dei pesi di ciascuno degli elementi dell'hidden layer, con i parametri d'input.
- **Hidden Layer:** sono tutti i layer che non sono né input né output. Il numero di hidden layer definisce la profondità della rete neurale. Una rete neurale si dice profonda (deep) quando si hanno $2 \leq \text{hidden layers}$. Il numero di neuroni può cambiare da layer a layer. Il layer n -esimo comunica col layer $n + 1$ -esimo.
- **Output Layer:** riunisce i dati in output. La funzione di attivazione dell'output layer dipende fortemente dal tipo di task. Tra queste funzioni, abbiamo ad esempio la sigmoide, la tangente iperbolica, la softplus o la ReLU.

Nelle reti neurali, individuiamo due parti fondamentali:




Figura 6.2: Un multilayer perceptron

Nella rete neurale fornita, individuiamo due parti.


- La parte in viola della rete è dedicata alla **trasformazione degli input grezzi** in qualcosa di utile per il task. La trasformazione viene appresa in fase di training grazie alle etichette note dell'apprendimento supervisionato. In questo caso, permette di trasformare $x \rightarrow a^{(2)}$.
- La parte arancione invece è dedicata alla **classificazione** (tramite softmax, o regressore logistico nella classificazione binaria), prendendo come input i dati trasformati dal resto della rete, in questo caso $a^{(2)}$. Basta sostituire il softmax con un regressore lineare per usare la rete su task di regressione.

6.2 Le funzioni di attivazione

Le funzioni di attivazione devono essere derivabili per consentire il training della rete tramite algoritmo di discesa del gradiente e di backpropagation. Tra le funzioni più usate, abbiamo:

Nome	Equazione	Derivata
Identità	$f(x) = x$	$f'(x) = 1$
Gradino binario (Binary step)	$f(x) = \begin{cases} 0 & \text{per } x < 0, \\ 1 & \text{per } x \geq 0 \end{cases}$	$f'(x) = \begin{cases} 0 & \text{per } x \neq 0, \\ ? & \text{per } x = 0 \end{cases}$
Logistica (o Soft step)	$f(x) = \frac{1}{1 + e^{-x}}$	$f'(x) = f(x)(1 - f(x))$
TanH	$f(x) = \tanh(x) = \frac{2}{1 + e^{-2x}} - 1$	$f'(x) = 1 - f(x)^2$
ArcTan	$f(x) = \tan^{-1}(x)$	$f'(x) = \frac{1}{x^2 + 1}$
Unità lineare rettificata (ReLU)	$f(x) = \begin{cases} 0 & \text{per } x < 0, \\ x & \text{per } x \geq 0 \end{cases}$	$f'(x) = \begin{cases} 0 & \text{per } x < 0, \\ 1 & \text{per } x \geq 0 \end{cases}$
Unità lineare rettificata parametrica (PReLU)	$f(x) = \begin{cases} \alpha x & \text{per } x < 0, \\ x & \text{per } x \geq 0 \end{cases}$	$f'(x) = \begin{cases} \alpha & \text{per } x < 0, \\ 1 & \text{per } x \geq 0 \end{cases}$
Unità lineare esponenziale (ELU)	$f(x) = \begin{cases} \alpha(e^x - 1) & \text{per } x < 0, \\ x & \text{per } x \geq 0 \end{cases}$	$f'(x) = \begin{cases} f(x) + \alpha & \text{per } x < 0, \\ 1 & \text{per } x \geq 0 \end{cases}$
SoftPlus	$f(x) = \log_e(1 + e^x)$	$f'(x) = \frac{1}{1 + e^{-x}}$

Riportiamo alcuni dei plotting delle funzioni di attivazione e le loro derivate.



6.2.1 Il teorema di approssimazione universale - *Universal Approximation Theorem*

Il teorema di approssimazione universale afferma che una rete neurale con un singolo strato nascosto può approssimare qualsiasi funzione continua con un livello di precisione arbitrario. Il layer potrebbe tuttavia essere estremamente numeroso e potrebbe soffrire di overfitting.

6.3 Training e inferenza di una rete neurale




Figura 6.3: Struttura tipica di una rete neurale per la classificazione.

Durante la fase di training, il nostro obiettivo è quello di stabilire i migliori parametri per il nostro modello sui dati di training. Usiamo quindi la Loss function e la nostra procedura di training. Usiamo poi il modello con i parametri ottenuti per fare inferenza su nuovi dati, e osservare le performance del modello.

6.3.1 Funzione di costo

Definiamo la nostra funzione di costo.

$$J(\vartheta) = -\frac{1}{m} \sum_{i=1}^m \underbrace{\sum_{c=1}^k \mathbf{1}\{y^{(i)} = c\} \log(h_{\vartheta}^{(c)}(x^{(i)}))}_{\text{Cross Entropy Loss Function}}$$

in cui

- m = numero di esempi nel dataset
- k = numero di classi
- $(x^{(i)})$ = i -esimo input
- $(y^{(i)})$ = etichetta (classe corretta) dell' i -esimo esempio
- $(\mathbf{1}(y^{(i)} = c))$ = funzione indicatrice: vale 1 se l'esempio (i) appartiene alla classe (c) , altrimenti 0
- $(h_{\vartheta}^{(c)}(x^{(i)}))$ = output della rete (probabilità predetta) per la classe (c) sull'esempio (i)

Il nostro obiettivo è quello di trovare $\hat{\vartheta}$, ossia i valori dei parametri ϑ , tali che

$$\hat{\vartheta} = \min(J(\vartheta))$$

6.3.2 Chain Rule

Considerando le reti neurali come delle funzioni composte, o annidate, è possibile usare la chain rule per le derivate di funzioni composte.


$$\frac{\partial J(\vartheta)}{\partial \vartheta_{i,j}^{(l)}} \quad \forall j, i, l$$

6.3.3 Inizializzazione dei parametri

L'inizializzazione dei parametri avviene con numeri casuali molto piccoli $\in [-\varepsilon, +\varepsilon]$. I parametri dei nodi che dipendono dallo stesso nodo, devono essere diversi tra loro, effettuando quella che è nota come **simmetry breaking**. Valori uguali sui nodi, porteranno i nodi a comportarsi in maniera simile, rendendo inutile avere modelli più complessi.

6.3.4 Reti neurali per regressione

Usiamo come Loss function l'errore quadratico medio (MSE). Ogni output sarà un regressore lineare, e la Loss function valuterà gli output di tutti i regressori.



6.4 Overfitting e Underfitting nelle reti neurali

Underfitting. Le reti neurali più piccole, su dati molto complessi, sono soggette ad underfitting. I pochi parametri non permettono di descrivere (o separare) i pattern complessi dei dati. Si riscontrano alti errori già in fase di training. Reti più semplici sono però più veloci da allenare.

Overfitting. Le reti neurali più complesse, con tanti parametri, imparano meglio i dati in fase di training, minimizzando o addirittura azzerando la loss function. Il rischio è opposto: il modello diventa troppo specifico, e non riesce a generalizzare sui dati di testing, cascando in overfitting. Diventa quindi necessario introdurre termini di regolarizzazione (λ) o cambiare modello. Modelli più vasti richiedono inoltre risorse computazionali più importanti.

Capitolo 7

Decision Tree

Gli alberi decisionali (decision tree) sono modelli utilizzati per la classificazione e la regressione. Essi rappresentano un insieme di regole decisionali organizzate in una struttura ad albero, dove ogni nodo interno rappresenta una condizione su una caratteristica dei dati, ogni ramo rappresenta l'esito della condizione e ogni foglia rappresenta una classe o un'etichetta di output.

7.1 Alberi di classificazione

Un albero decisionale per la classificazione è una struttura gerarchica composta da nodi interni e foglie. Ogni nodo interno rappresenta un test su una caratteristica specifica del dataset, mentre ogni foglia rappresenta una classe di output. L'obiettivo principale di un albero decisionale è suddividere il dataset in modo tale che le tuple appartenenti alla stessa classe siano raggruppate insieme nelle foglie dell'albero.

Questo approccio, comunemente chiamato **divide and conquer**, suddivide iterativamente il dataset in sottoinsiemi più piccoli basati su condizioni specifiche, fino a quando non si raggiungono le foglie dell'albero che rappresentano le decisioni finali.

7.1.1 Divisione ricorsiva

La classe di una tupla q si ottiene seguendo il cammino radice $\rightarrow$ foglia guidato dai blocchi condizionali sui nodi interni. Ogni nodo interno applica un test su una caratteristica A e, in base al risultato del test, si procede lungo il ramo corrispondente fino a raggiungere una foglia che fornisce la classificazione finale. L'insieme di regole *deve* essere **esaustivo** e **mutuamente esclusivo**¹ (ogni tupla deve essere classificata da una e una sola regola).

La costruzione dell'albero decisionale è molto semplice:

1. Se tutte le tuple del nodo X hanno la *stessa* classe C , crea una foglia C .
2. Altrimenti scegli un attributo A (non ancora usato) e *ramifica* X (*splitting*) secondo i valori/soglia di A ; crea i figli.

¹Se così non fosse, alcune tuple potrebbero non essere classificate o potrebbero essere classificate da più regole contemporaneamente

3. Per ogni figlio X_i : se puro, fermati; se impuro, ripeti ricorsivamente.

Pruning. Se le tuple nel nodo sono poche o la profondità è elevata, si può fermare prima e rendere il nodo una foglia (vedere figura 7.1 con l'attributo "overcast").




Figura 7.1: Dataset *weather* (a sinistra) e albero decisionale appreso (a destra). La tabella contiene 14 esempi con quattro attributi descrittivi (**Outlook**, **Temperature**, **Humidity**, **Windy**) e la classe binaria **P/N**. L'albero (stile ID3/C4.5) sceglie come radice **Outlook**; il ramo **overcast** porta direttamente alla classe **P**, mentre per **sunny** si testa **Humidity** e per **rain** si testa **Windy**. L'esempio illustra il passaggio da dati tabellari a regole interpretabili.

7.1.2 Migliore divisione dei nodi

Diciamo che per il nodo m , N_m è il numero di tuple nel training set che raggiungono il nodo m (per la radice, $N_{root} = N$, il numero totale di tuple). Sia N_m^i il numero di tuple di classe C_i che raggiungono il nodo m , con $\sum_i N_m^i = N_m$. Sapendo che una tupla x raggiunge il nodo m , la probabilità stimata che appartenga alla classe C_i è:

$$\hat{P}(C_i|x, m) \equiv p_m^i = \frac{N_m^i}{N_m}$$

Definiamo un **nodo puro** come un nodo in cui tutte le tuple appartengono alla stessa classe:

$$\exists i : N_m^i = N_m \implies p_m^i = 1 \quad \text{e} \quad \forall j \neq i : p_m^j = 0$$

ovvero la probabilità stimata di una classe è 1, mentre per tutte le altre è 0. Un nodo è **impuro** se contiene tuple di classi diverse. Un modo frequente per misurare l'impurità di un nodo è utilizzare l'entropia di Shannon:

$$H(m) = - \sum_i p_m^i \log_2(p_m^i)$$

L'entropia misura l'incertezza associata alla distribuzione delle classi nel nodo. Un nodo puro ha *entropia zero*, mentre un nodo con una distribuzione uniforme delle classi ha *entropia massima*.

Per trovare la miglior combinazione dei nodi eseguiamo la seguente procedura ricorsiva:

- Se il nodo è *puro*, creiamo una foglia con la classe corrispondente.
- Altrimenti, per ogni attributo A non ancora usato, si divide.

Per calcolare l'impurità dei nodi dopo lo splitting (un nodo impuro) bisogna diminuire il valore di impurità. Per calcolarlo:

$$\hat{P}(C_i|x, m, j) \equiv p_{mj}^i = \frac{N_{mj}^i}{N_{mj}}$$

dove N_{mj} è il numero di tuple che raggiungono il figlio j del nodo m e N_{mj}^i è il numero di tuple di classe C_i che raggiungono il figlio j del nodo m . Questo si traduce in una nuova entropia calcolata come:

$$H^j(m) = - \sum_{j=1}^n \frac{N_{mj}}{N_m} \sum_i^k p_{mj}^i \log_2(p_{mj}^i)$$

dove n è il numero di figli del nodo m e k è il numero di classi. L'entropia dopo lo splitting è una media pesata delle entropie dei figli, ponderata per la proporzione di tuple che raggiungono ciascun figlio.

7.2 Alberi di regressione

Un albero di regressione è un modello predittivo utilizzato per stimare valori continui basati su un insieme di caratteristiche. A differenza degli alberi decisionali per la classificazione, che suddividono i dati in classi discrete, gli alberi di regressione suddividono i dati in intervalli continui e forniscono una stima numerica come output.

7.2.1 Costruzione dell'albero di regressione

Ipotizziamo di avere un nodo m , con $\mathcal{X}_m$ che rappresenta l'insieme $\mathcal{X}$ delle tuple che raggiungono il nodo m . Quindi è l'insieme di tutti quei nodi x tali che $x \in \mathcal{X}$ e x raggiunge il nodo m . Possiamo definire:

$$b_m(x) = \begin{cases} 1 & \text{se } x \in \mathcal{X}_m \\ 0 & \text{altrimenti} \end{cases}$$

ovvero una funzione indicatrice che vale 1 se la tupla x raggiunge il nodo m e 0 altrimenti.

Nella regressione, la *goodness*² di una divisione viene misurata utilizzando la somma dei quadrati degli errori (SSE, Sum of Squared Errors). Per un nodo m , la SSE è definita

²Qualità

come:

$$E_m = \frac{1}{N_m} \sum_t (y^t - \hat{y}_m)^2 b_m(x^t)$$

dove y^t è il valore reale della tupla t , $\hat{y}_m$ è la stima associata al nodo m , e N_m è il numero di tuple che raggiungono il nodo m . Si moltiplica per la funzione indicatrice $b_m(x^t)$ per considerare solo le tuple che effettivamente raggiungono il nodo m . La stima media $\hat{y}_m$ per il nodo m è calcolata come:

$$\hat{y}_m = \frac{\sum_t b_m(x^t) y^t}{\sum_t b_m(x^t)} = \frac{1}{N_m} \sum_t b_m(x^t) y^t$$

dove la somma è calcolata su tutte le tuple t che raggiungono il nodo m . In pratica, $\hat{y}_m$ è la media dei valori di output delle tuple che raggiungono il nodo m .

7.2.2 Divisione di un nodo

Per dividere un nodo m , si seleziona un attributo A e una soglia di divisione. La divisione crea più figli per il nodo m , ciascuno corrispondente a un intervallo di valori dell'attributo A . Dopo la divisione, si calcola l'errore E_m^j per ciascun figlio j del nodo m .

Se l'errore E_m viene ritenuto accettabile, ovvero $E_m < \theta_r$ per una certa soglia, si crea una foglia con la stima $\hat{y}_m$. Altrimenti, se l'errore non è accettabile, si procede viene diviso tante volte finché non si raggiunge una stima accettabile o si esauriscono gli attributi disponibili per la divisione. Si definisce $\mathcal{X}_{mj}$ come l'insieme delle tuple che raggiungono il figlio j del nodo m sottoinsieme di $\mathcal{X}_m$. Definiamo ulteriormente:

$$b_{mj}(x) = \begin{cases} 1 & \text{se } x \in \mathcal{X}_{mj} \\ 0 & \text{altrimenti} \end{cases}$$

La stima media per il figlio j del nodo m è calcolata come:

$$\hat{y}_{mj} = \frac{\sum_t b_{mj}(x^t) y^t}{\sum_t b_{mj}(x^t)} = \frac{1}{N_{mj}} \sum_t b_{mj}(x^t) y^t$$

dove N_{mj} è il numero di tuple che raggiungono il figlio j del nodo m . L'errore dopo lo split è calcolato come:

$$E_m^j = \frac{1}{N_m} \sum_t \sum_j (y^t - \hat{y}_{mj})^2 b_{mj}(x^t)$$

dove la somma esterna è calcolata su tutte le tuple t che raggiungono il nodo m e la somma interna è calcolata su tutti i figli j del nodo m . Ipotezziamo di avere un nodo m , con X_m che rappresenta l'insieme X delle tuple che raggiungono il nodo m . Quindi è l'insieme di tutti quei nodi x tali che $x \in X$ e x raggiunge il nodo m .

7.3 Pruning: riduzione dell'albero

Il pruning è una tecnica utilizzata per ridurre la complessità di un albero decisionale (di classificazione) o di regressione, al fine di migliorare la sua capacità di generalizzazione sui dati non visti. Durante la costruzione dell'albero, è possibile che si creino nodi che si adattano troppo strettamente ai dati di addestramento, portando ad *overfitting*. Il pruning mira a rimuovere questi nodi superflui, semplificando l'albero e migliorando le prestazioni sui dati di test.




Figura 7.2: Esempio di albero di regressione in cui si mostra l'effetto del parametro di complessità θ_r sulla funzione stimata: al diminuire di θ_r l'albero produce più suddivisioni e una funzione a gradini più irregolare e aderente ai dati.

7.3.1 Pre-pruning

Il pre-pruning consiste nell'interrompere la crescita dell'albero prima che raggiunga la sua massima profondità. Durante la costruzione dell'albero, si valuta la bontà³ di ogni divisione e si decide di fermarsi se la divisione non migliora significativamente le prestazioni del modello. Questo può essere fatto utilizzando criteri come la riduzione dell'impurità o la diminuzione dell'errore di regressione.

³La bontà indica la qualità di misura.

7.3.2 Post-pruning

Il post-pruning, invece, avviene dopo che l'albero è stato completamente costruito. In questa fase, si esaminano i nodi dell'albero e si valutano le prestazioni del modello su un set di validazione. I nodi che non contribuiscono significativamente alla precisione del modello vengono rimossi, in quanto contribuiscono all'*overfitting*, e i loro figli vengono sostituiti con foglie che rappresentano la stima media o la classe più frequente delle tuple che raggiungevano quel nodo.

7.4 Regole di learning

Generalmente il metodo IF-THEN funziona per addestrare un albero decisionale e dopo convertire questo in regole. Altri metodi riguardano l'apprendimento sulle **regole stesse**: invece di costruire un albero e poi estrarre le regole, si *imparano* le regole dai dati e dopo si costruisce l'albero, procedura nota come **rule induction**.

7.4.1 Rule induction

Una regola è generalmente espressa nella forma:

IF condition(s) THEN conclusion

dove le *condition(s)* sono un insieme di test su attributi e la *conclusion* è una classe (per classificazione) o una stima (per regressione). L'obiettivo dell'apprendimento delle regole è identificare un insieme di regole che descrivano accuratamente i dati di addestramento.

Sequential Covering. Le *condition* possono essere combinate utilizzando operatori logici come AND e OR per formare regole più complesse. Ad esempio, una regola potrebbe essere:

IF ($A_1 > 5$) AND ($A_2 = 'Yes'$) THEN Class = Positive

e si aggiungono **una alla volta** per ottimizzare una certa *euristica* (per esempio l'entropia o la riduzione dell'errore). Nell'esempio di prima, si inizia con la prima regola $R_1 = A_1 > 5$, si valuta la bontà di R_1 e si continua ad aggiungere condizioni finché non si raggiunge un certo criterio di arresto (ad esempio, la regola copre un numero sufficiente di tuple positive senza coprire troppe tuple negative). Una volta che una regola è stata appresa, le tuple coperte da quella regola vengono rimosse dal dataset e il processo continua con le tuple rimanenti fino a quando tutte le tuple sono state coperte o non è possibile apprendere ulteriori regole utili.

Differenza con alberi decisionali. Mentre gli alberi decisionali suddividono i dati in modo gerarchico, le regole di apprendimento si concentrano sull'identificazione di condizioni specifiche che portano a conclusioni. Le regole possono essere più flessibili e interpretabili rispetto agli alberi decisionali, poiché possono essere applicate in modo indipendente l'una dall'altra. Si parla infatti di:

Breadth-First Questo approccio, utilizzato dagli alberi decisionali, esplora tutte le possibili divisioni, in modo parallelo, ad ogni livello dell'albero prima di procedere al livello successivo (quindi cresce in *larghezza*).

Depth-First Questo approccio, utilizzato dalle regole di apprendimento, esplora una singola divisione alla volta, procedendo in profondità lungo un percorso specifico prima di tornare indietro e esplorare altre divisioni (quindi cresce in *profondità*).

7.4.2 Copertura delle regole

Si dice che una regola **copre** una tupla t se le condizioni della regola sono soddisfatte dalla tupla t . L'insieme delle tuple coperte da una regola è chiamato **coverage** (copertura) della regola. La copertura aiuta a **valutare** l'efficienza di una regola: una regola con una copertura elevata è generalmente considerata più utile, poiché si applica a un numero maggiore di tuple nel dataset.

Ripper. Un esempio può essere Ripper (Repeated Incremental Pruning to Produce Error Reduction), un algoritmo di apprendimento delle regole che utilizza una strategia di copertura sequenziale per generare un insieme di regole a partire dai dati di addestramento. Ripper:

1. Inizia con un insieme vuoto di regole $\mathcal{R} = \emptyset$.
2. Ripete fino a quando tutte le tuple positive sono coperte:
 - (a) Crea una nuova regola R iniziando con una condizione vuota.
 - (b) Aggiunge condizioni a R finché la regola non soddisfa un criterio di arresto (ad esempio, copre un numero sufficiente di tuple positive senza coprire troppe tuple negative).
 - (c) Aggiunge la regola R all'insieme delle regole $\mathcal{R}$.
 - (d) Rimuove le tuple coperte da R dal dataset.

7.5 Alberi decisionali multivariati

Nel caso di alberi decisionali univariati, ogni nodo interno effettua un test su un singolo attributo alla volta. Si considera quindi una funzione del tipo:

$$f(x) = \begin{cases} \text{figlio destro} & \text{se } A_i \leq \theta \\ \text{figlio sinistro} & \text{se } A_i > \theta \end{cases}$$

dove A_i è un singolo attributo e θ è una soglia. Questo approccio è semplice e facile da interpretare, ma potrebbe non catturare tutte le relazioni complesse tra gli attributi.

7.5.1 Alberi decisionali multivariati lineari

In alcuni casi, potrebbe essere vantaggioso considerare più attributi contemporaneamente per prendere decisioni più complesse, portando alla creazione di *alberi decisionali multivariati lineari* dove si considera una **combinazione lineare** di attributi in ogni nodo:

$$f_m(x) = \mathbf{w}_m^T \cdot x + w_{m0} > 0$$

dove $\mathbf{w}_m$ è un vettore di pesi associati agli attributi, x è il vettore delle caratteristiche della tupla, e w_{m0} è un termine di bias. In questo caso, la decisione su quale figlio seguire dipende dalla valutazione di una combinazione lineare di tutti gli attributi, piuttosto che da un singolo attributo. Questo consente di catturare relazioni più complesse tra gli attributi e può portare a una migliore performance del modello in alcuni scenari.

7.5.2 Interpretazione geometrica

L'uso di combinazioni lineari di attributi in ogni nodo può essere interpretato geometricamente come la suddivisione dello spazio delle caratteristiche in regioni definite da iperpiani. In particolare, la funzione di decisione $f_m(x)$ definisce un iperpiano nello spazio delle caratteristiche, che separa lo spazio in due metà: una metà in cui la condizione è vera (portando al figlio destro) e l'altra metà in cui la condizione è falsa (portando al figlio sinistro) (figura 7.3).




Figura 7.3: Esempio di nodo multivariato: a sinistra, gli esempi delle due classi C_1 (cerchi) e C_2 (quadrati) vengono separati da un iperpiano lineare dove $w_{11}x_1 + w_{12}x_2 + w_{10} = 0$. A destra è mostrato il corrispondente nodo dell'albero di decisione, che instrada gli esempi in base al test $w_{11}x_1 + w_{12}x_2 + w_{10} > 0$.

7.5.3 Alberi decisionali multivariati non lineari

Il concetto di alberi decisionali multivariati può essere esteso ulteriormente per includere funzioni non lineari nei nodi. In questo caso, invece di utilizzare una combinazione lineare di

attributi, si possono utilizzare funzioni non lineari più complesse, come polinomi, funzioni radiali o reti neurali. Ad esempio, un nodo potrebbe utilizzare una funzione del tipo:

$$f_m(x) : x^T \mathbf{W}_m x + \mathbf{w}_m^T x + w_{m0} > 0$$

dove $\mathbf{W}_m$ è una matrice di pesi che definisce una funzione quadratica. Questo approccio consente di catturare relazioni ancora più complesse tra gli attributi, ma può rendere l'interpretazione del modello più difficile.

In generale, una funzione non lineare può essere rappresentata come:

$$f_m(x) = g_m(x) > 0$$

dove $g_m(x)$ è una funzione non lineare definita sui dati di input. L'uso di funzioni non lineari nei nodi può migliorare la capacità del modello di adattarsi a dati complessi, ma richiede anche tecniche di ottimizzazione più sofisticate per addestrare l'albero decisionale e non finire in overfitting.

Riferimenti

Il materiale di questo capitolo comprende:

- Materiale visto a lezione.
- Capitolo 9 del libro *Introduction to Machine Learning* [1].

Capitolo 8

Random Forests, Ferns, Meta-Algoritmi

8.1 Meta algoritmi nel machine learning

Un meta-algoritmo, nel contesto del machine learning, rappresenta un modo di combinare più modelli, detti *weak learner*. Tra questi, studiamo

Tree hierarchy Definita come una gerarchia di domande (*weak learner*). Ogni nodo è un modello. La struttura ad albero permette di soeizzare lo spazio delle feature in varie regioni. I decision tree classifici rappresentano un caso particolare di questo meta-algoritmo. È una struttura facile da interpretare (*if-then-else*). Un albero decisionale è una particolare istanza di questo.

Bagging (Bootstrap Aggregating) Migliora i modelli di classificazione, in termini di stabilità e precisione. Riduce la varianza e permette di evitare l'overfitting. Dato un training set I di dimensione n , il bagging genera m nuovi training set I_i , ognuno di essi di dimensione $n' < n$, campionando esempi da I^1 . Ciascuno dei sotto-training set allena un modello differente. L'output complessivo è una media o una votazione.

Boosting Gli algoritmi di boosting consistono nell'allenare iterativamente dei classificatori deboli secondo una distribuzione. Questi vengono poi aggiunti al classificatore complessivo in maniera pesata ("quanto conta questo classificatore nella valutazione complessiva?"). Il peso è solitamente proporzionale all'accuracy del singolo modello.

Trattiamo questi meta-algoritmi, in quanto permettono di ottenere dei modelli strutturalmente semplici, ma sempre più precisi e meno proni a overfitting.

¹Potrebbe ricordare la k -fold validation. Tuttavia, se il bagging è un metodo per ridurre l'overfitting, la cross validation viene utilizzata per stimare l'accuratezza del modello fuori dal campione di training.

8.2 Decision stump - Ceppo di decisione

È un albero decisionale a singolo nodo. Può essere univariato o multivariato. Data la loro semplicità, sono dei classificatori lineari. Saranno i nostri *weak learners*.




Figura 8.1: Meta-Algoritmi applicati sui decision stump.

8.3 Decision Trees

Applichiamo la **tree hierarchy** sui nostri decision stump, ottenendo una gerarchia di decisioni. Tramite una serie di domande di tipo "yes/no", o varie sogliature, diventa possibile classificare categorie sempre più specifiche. Ogni coppia di risultati di un nodo di un decision tree, è detta *split*. La profondità (direttamente proporzionale al numero di split), definisce la complessità del modello. Alberi decisionali troppo profondi rischiano di cadere in overfitting.

8.4 Random Ferns

Applicando il bagging sullo stump, otteniamo i random ferns. Queste hanno riscontrato molte applicazioni in task di object detection, tramite previa suddivisione delle immagini in *patches*. La semplicità dei singoli fern offre possibilità di parallelizzazione banale. In

particolar modo, i modelli di object detection riprendono le intuizioni dietro i classificatori bayesiani².

8.5 Random Tree

Un random tree è un decision tree costruito con dei parametri scelti da un insieme di proposte casuali. Per ogni nodo, un set di linee viene valutato, e il rispettivo parametro viene fissato nel modello. L'obiettivo a ogni passo è massimizzare l'informazione ottenuta a ogni passo.

8.5.1 Randomized learning

Si utilizza un algoritmo ricorsivo.

$$\text{Left split: } I_l = \{i \in I_n | f(v_i) < t\} \quad \text{Right split: } I_r = I_n \setminus I_l$$

con t soglia, threshold scelta dal range del minimo e del massimo di $f(v_i)$. L'obiettivo è ottenere il massimo guadagno di informazione, ossia

$$\Delta E = -\frac{|I_l|}{|I_n|}E(I_l) - \frac{|I_r|}{|I_n|}E(I_r)$$


8.6 Random forest

Le random forest nascono dall'unione delle intuizioni relative al bagging e alla tree hierarchy. Si basano sulla combinazione di output di più decision trees (spesso random trees) per ottenere un unico risultato. La loro facilità d'uso e la flessibilità ne hanno favorito l'adozione, e possono essere usate sia su task di classificazione che di regressione. Offrono un ottimo grado di **precisione**, **cadono meno facilmente in overfitting** e sono assolutamente **multi-core friendly**.

La classificazione è ottenuta considerando la distribuzione media computata dalle foglie.

$$\frac{1}{T} \sum_{t=1}^T P_t(c|v)$$

²Un classificatore bayesiano è un classificatore basato sull'applicazione del teorema di Bayes. Il classificatore bayesiano richiede la conoscenza delle probabilità a priori e condizionali relative al problema, quantità che in generale non sono note ma sono tipicamente stimabili.



Capitolo 9

SVM: Support Vector Machines

Le SVM sono modelli di machine learning supervisionato che possono essere utilizzati sia per problemi di classificazione che di regressione. L'idea alla base delle SVM è trovare un iperpiano che separi i dati di diverse classi con il massimo margine possibile: sono quindi una delle soluzioni più eleganti e semplici da visualizzare per quando riguarda la classificazione. L'iperpiano scelto non solo separa le classi, ma lo fa in modo tale da **massimizzare la distanza tra l'iperpiano e i punti** più vicini di ciascuna classe, noti come vettori di supporto.

9.1 Iperpiani di separazione

Dati i vettori x_i e x_j , un modo di definirne la similarità è il prodotto scalare tra i due¹ :

$$\langle x_i, x_j \rangle = x_i^T x_j$$

Il valore di questo prodotto dipende dalla norma² dei due vettori. Questo permette di definire un iperpiano di separazione come l'insieme dei punti x che soddisfano l'equazione:

$$\langle w, x \rangle + b = 0$$

dove w è un vettore normale all'iperpiano e b è l'intercetta.

9.1.1 Funzione di decisione lineare

L'idea principale dietro a diversi algoritmi di classificazione è quello di rappresentare i dati in uno spazio $\mathbb{R}^d$, dove d è il numero di features del piano, e trovare quel *decision boundary* grazie al quale l'algoritmo è capace di separare le diverse classi. Nel caso di una classificazione binaria si separa lo spazio in due regioni corrispondenti alla classe positiva e negativa e si cerca quell'iperpiano che separa le due regioni. Sia $x \in \mathbb{R}^d$ un esempio nello

¹In generale, il prodotto scalare tra due vettori a e b è definito come $a^T b$, dove a^T è la trasposizione di a .

²La norma di un vettore è una misura della sua lunghezza o grandezza, come il modulo di un vettore in uno spazio euclideo.

spazio dei dati, consideriamo la funzione:

$$f : \mathbb{R}^d \rightarrow \mathbb{R}, \quad f(x) := \langle w, x \rangle + b$$

dove $w \in \mathbb{R}^d$ e $b \in \mathbb{R}$ sono rispettivamente il vettore dei pesi e il bias. In questo modo, un iperpiano può essere definito come il **separatore** lineare delle due classi, ovvero:

$$\{x \in \mathbb{R}^d : f(x) = 0\} \quad (9.1)$$




Figura 9.1: Esempio di iperpiano come frontiera di decisione: il vettore w è normale all'iperpiano e ne determina l'orientamento, mentre il termine b ne stabilisce la posizione rispetto all'origine, separando i punti delle due classi sul lato positivo e su quello negativo.

9.1.2 Interpretazione geometrica

Come si vede in figura 9.1, il vettore w è normale³ all'iperpiano e ne determina l'orientamento, mentre il termine b ne stabilisce la posizione rispetto all'origine, separando i punti delle due classi sul lato positivo e su quello negativo. Questo è anche possibile dimostrarlo prendendo in considerazione due esempi x_a, x_b giacenti sull'iperpiano:

$$\begin{aligned} f(x_a) &= f(x_b) \\ \Rightarrow f(x_a) - f(x_b) &= 0 \\ \Rightarrow \langle w, x_a \rangle + b - (\langle w, x_b \rangle + b) &= 0 \\ \Rightarrow \langle w, x_a - x_b \rangle &= 0 \end{aligned}$$

Utilizzando l'equazione dell'iperpiano (9.1), possiamo, per un certo esempio x capire se si tratta di una classe positiva o negativa a seconda della regione in cui si trova rispetto

³Un vettore è normale a un iperpiano se è perpendicolare a ogni vettore che giace sull'iperpiano.

all'iperpiano:

$$y = \begin{cases} +1 & \text{se } f(x) \geq 0 \\ -1 & \text{se } f(x) < 0 \end{cases}$$

dove y è l'etichetta di classe associata all'esempio x e $f(x)$ è l'equazione dell'iperpiano. Questo si può rappresentare in una singola equazione come:

$$y \cdot (\langle w, x \rangle + b) \geq 0$$

9.2 Primal SVM

Questa formulazione delle SVM ha l'obiettivo di trovare quell'iperpiano che massimizza il margine tra le due classi. Ipotizziamo un dataset $\{(x_1, y_1), \dots, (x_n, y_n)\}$ linearmente separabile, dove $x_i \in \mathbb{R}^d$ sono gli esempi e $y_i \in \{-1, +1\}$ sono le etichette di classe. Esistono infiniti iperpiani che possono separare le due classi, ma possiamo dire che un iperpiano è migliore di un altro se performa meglio sui dati di test. Formuliamo quindi un vero e proprio **problema di ottimizzazione**, cui risoluzione ci offrirà i valori ottimali di w e b .

9.2.1 Concetto di margine

Per ottenere questo iperpiano, dobbiamo trovare quello che massimizza il margine: è la distanza che separa l'iperpiano dai punti dati **più vicini** di ciascuna classe.

Scala dei dati. Un problema di trovare le distanze minime è che non tutte le feature potrebbero avere la stessa scala di valori. Questo si può anche dimostrare matematicamente, dicendo che la scala dell'iperpiano dipende da w e b . Infatti, se moltiplichiamo entrambi per una costante positiva $\alpha > 0$, otteniamo lo stesso iperpiano:

$$\langle \alpha w, x \rangle + \alpha b = 0$$

Per risolvere questo, si fissa una scala non sui dati ma direttamente sui parametri del modello. In particolare, preso un punto x_a e la sua proiezione corrispondente sull'iperpiano x'_a si può calcolare la distanza r tra i due (ovvero tra il punto e l'iperpiano):

$$r = \frac{1}{\|w\|}$$

dove $\|w\|$ è la norma del vettore w . Questo valore r è esattamente il *margine*, o scala, che vogliamo fissare. Una volta trovato R possiamo lavorare sulla distanza assoluta tra x_a e x'_a :

$$x_a = x'_a + r \frac{w}{\|w\|} = x'_a + r \hat{w}$$

dove $\hat{w} = \frac{w}{\|w\|}$ è il versore nella direzione di w . Un altro modo di pensare r è come la coordinata di x_a nella direzione del sottospazio generato da $w/\|w\|$.




Figura 9.2: Distanza r tra un punto x_a e la sua proiezione x'_a sull'iperpiano di separazione.

Ricordando che vogliamo che gli esempi positivi siano al di sopra dell'iperpiano e quelli negativi al di sotto, possiamo scrivere la seguente condizione per ogni esempio x_i :

$$y_i(\langle w, x_i \rangle + b) \geq r$$

ovvero, un esempio positivo ($y_i = +1$) deve essere almeno a distanza r dall'iperpiano, mentre un esempio negativo ($y_i = -1$) deve essere almeno a distanza r dall'iperpiano sul lato opposto.

Margine unitario. Poiché siamo interessati unicamente alla direzione di w , possiamo imporre che il vettore dei pesi abbia norma unitaria, ovvero:

$$\|w\| = 1.$$

Questa scelta non modifica l'orientamento dell'iperpiano, ma rende l'interpretazione del margine più immediata: con $\|w\| = 1$, la distanza r coincide direttamente con lo spostamento lungo la direzione normale all'iperpiano. Con questa convenzione, la condizione

$$y_i(\langle w, x_i \rangle + b) \geq r$$

impone che tutti gli esempi si trovino almeno a distanza r dall'iperpiano, nel verso coerente con la loro etichetta. Questo vincolo compatto unifica i requisiti delle due classi: gli esempi positivi sono almeno a distanza r nella direzione di w , mentre quelli negativi sono almeno a distanza r nella direzione opposta.

Negli SVM, si può sempre assumere (senza perdita di generalità) che i vincoli siano

$$y_n(\langle w, x_n \rangle + b) \geq 1$$

9.2.1.1 Approfondimento - dimostrazione del teorema del margine a 1

Imponiamo $\|w\| = 1$. Questo può essere scritto come $w = \frac{w'}{\|w'\|}$, dove w' è un vettore di parametri qualsiasi non normalizzato. Sostituendo nella formulazione iniziale, otteniamo

$$y \left(\left\langle \frac{w'}{\|w'\|}, x \right\rangle + b \right) \geq r$$

Noto che $r \geq 0$ in quanto una distanza euclidea, possiamo andare a dividere l'intero vincolo per r . Otteniamo:

$$y \left(\left\langle \frac{w'}{\|w'\|r}, x \right\rangle + \underbrace{\frac{b}{r}}_{b'} \right) \geq 1$$

Bene, adesso definiamo $\|w''\| = \left\| \frac{w'}{\|w'\|r} \right\| = \frac{1}{r} \frac{\|w'\|}{\|w'\|} = \frac{1}{r}, \Rightarrow r = \frac{1}{\|w''\|}$.

Per facilitare la dimostrazione, imponiamo di dover massimizzare r^2 , ossia $\frac{1}{\|w''\|^2}$. Tuttavia, massimizzare questo valore, significa minimizzare $\|w''\|^2$, o, per semplificare il lavoro con le derivate, equivale a minimizzare $\frac{1}{2}\|w''\|^2$.

$$\min_{w'', b'} \frac{1}{2}\|w''\|^2 \quad y(\langle w'', x \rangle + b'') \geq 1$$

Data questa totale equivalenza, abbiamo dimostrato il teorema.

9.3 Soft Margin SVM

Nel caso di dati non linearmente separabili, potremmo desiderare di permettere ad alcuni esempi di cadere all'interno dell'area del margine, o addirittura di finire dalla parte sbagliata dell'iperpiano. Il modello che permette alcuni errori di classificazione, è detto **soft margin SVM**. Introduciamo una variabile, detta **variabile di slack**, indicata con ξ_n . Sottrarre questo termine, ci permetterà di rilassare i *constraints* relativi alla classificazione, consentendo errori.

$$\begin{aligned} \min_{w, b, \xi} \quad & \frac{1}{2}\|w\|^2 + C \sum_{n=1}^N \xi_n \\ \text{rispetto a} \quad & y_n(\langle w, x_n \rangle + b) \geq 1 - \xi_n, \\ & \xi_n \geq 0 \end{aligned}$$

La variabile di slack dovrà essere non-negativa. Il parametro $C > 0$ nella funzione obiettivo gestisce il tradeoff tra la dimensione del margine e la dimensione complessiva di rilassamento. È detto **parametro di regolarizzazione**. Indichiamo invece con il nome **regolarizzatore** il termine $\|w\|^2$, questo controlla la larghezza del margine.

- **C grande:** penalizzi molto le ξ_n . Il modello cercherà di commettere pochissimi errori, anche se questo porta ad avere un margine più stretto, rischiando **overfitting**.

- **C piccolo:** gli errori costano poco, accettando più violazioni, in cambio con un margine più grande, ottenendo un modello più regolare.

9.3.1 Soft Margin SVM e Loss function

Cambiamo il nostro approccio alle SVM, seguendo il **principio di minimizzazione del rischio empirico**⁴. Nel modello SVM, scegliamo come classe di ipotesi⁵ gli iperpiani, ossia funzioni del tipo

$$f(x) = \langle w, x \rangle + b$$

dove il margine, coincide con il termine di regolarizzazione. Affrontiamo adesso l'argomento relativo alla loss function, che dovrà essere mirata al task principale del modello, ossia classificazione binaria.

Zero-One Loss La **zero-one loss** potrebbe sembrare una buona idea: l'obiettivo è minimizzare il numero di mismatch tra la classe predetta e l'etichetta effettiva (y e $\hat{y}$). Questa funzione è denotabile con

$$\mathbf{1}(f(x_n)) \neq y_n$$

per quanto l'idea sembra funzionare, questo rende il training un vero e proprio problema di ottimizzazione combinatorio, i quali sono tendenzialmente molto complessi da risolvere. Scartiamo quindi l'idea.

Hinge Loss Consideriamo l'errore tra l'output del predittore $f(x_n)$ e l'etichetta y_n . La funzione di loss deve descrivere l'errore commesso sui dati di training. Ci aspettiamo errore 0 se la predizione è corretta, ed è fuori dal margine. Una predizione corretta all'interno del margine dovrà comunque essere penalizzata. Una predizione sbagliata verrà penalizzata, come da atteso.

$$L(t) = \max\{0, 1 - t\} \quad \text{con} \quad t = yf(x) = y(\langle w, x \rangle + b)$$

È altrimenti formulabile come una funzione definita a tratti:

$$L(t) = \begin{cases} 0 & \text{se } t \geq 1 \\ 1 - t & \text{se } t < 1 \end{cases}$$

⁴Nella teoria dell'apprendimento statistico, la minimizzazione del rischio empirico (in inglese empirical risk minimization, da cui la sigla ERM) è un principio che definisce una famiglia di algoritmi di apprendimento e viene utilizzato per fornire limiti teorici alle loro prestazioni. L'idea centrale è che non è possibile sapere esattamente quanto bene funzionerà un algoritmo nella pratica (il "rischio vero") perché è ignota la vera distribuzione dei dati su cui lavorerà l'algoritmo, ma è invece possibile misurarne le prestazioni su un insieme di dati di addestramento noto (il rischio "empirico").

⁵insieme di tutti i modelli possibili che consideriamo

9.4 Dual SVM

La formulazione di SVM descritta in precedenza, è nota come primal SVM. Ha variabili w e b , e w è di dimensione pari a $x \in \mathbb{R}^D$, con D features. Ne consegue che il problema di ottimizzazione cresce linearmente all'aumentare del numero di features. La seguente formulazione, crescerà invece col numero di esempi del dataset, non dipendendo più dal numero di features. Sarà inoltre semplice applicarne dei kernel, per separare meglio dati non linearmente separabili. Chiaremo questa formulazione **Dual SVM**, e si presenterà così:

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N y_i y_j \alpha_i \alpha_j \langle x_i, x_j \rangle - \sum_{i=1}^N \alpha_i \\ \text{soggetto a} \quad & \sum_{i=1}^N y_i \alpha_i = 0, \\ & 0 \leq \alpha_i \leq C \quad \text{per } i = 1, \dots, N. \end{aligned}$$

Prerequisito matematico: Lagrangiani Data una funzione f da ottimizzare, e un insieme di condizioni $g_1, \dots, g_n$, un **Lagrangiano** è una funzione $\mathcal{L}(f, g_1, \dots, g_n, \alpha_1, \dots, \alpha_n)$ che incorpora le condizioni del problema di ottimizzazione:

$$\mathcal{L}(f, \alpha_1, \dots, \alpha_n) = f(x_1, \dots, x_k) - \sum_{i=1}^n \alpha_i g_i(x_1, \dots, x_k)$$

Ad esempio, se $f(w) = \frac{w^2}{2}$ e $g_1(w, x) : wx - 1 \geq 0$, allora

$$\mathcal{L}(w, \alpha) = \frac{w^2}{2} - \alpha(wx - 1), \quad \alpha \geq 0$$

Si calcolano le varie derivate parziali rispetto alle variabili del Lagrangiano, in questo esempio w e α , e si impongono nulle. Si risolve poi il sistema di equazioni ottenuto, ottenendo i valori che soddisfano il problema. $\mathcal{L}$ dovrà essere massimizzata rispetto alle **variabili primarie** (w), ma minimizzata rispetto alle variabili duali (α).

$$L(f(w), \alpha) = \frac{w^2}{2} - \alpha(wx - 1), \quad \alpha \geq 0$$

$$\frac{\partial L}{\partial w} = w - \alpha x = 0 \Rightarrow w = \alpha x$$

$$\frac{\partial L}{\partial \alpha} = -wx = 0$$

9.4.1 Convex duality con Moltiplicatori di Lagrange

Dalle variabili della precedente formulazione, riprendiamo w, b, ξ . Usiamo $\alpha_n \geq 0$ come moltiplicatore corrispondente al constraint $y_n(\langle w, x_n \rangle + b) \geq 1 - \xi_n$, e $\gamma_n \geq 0$ come

moltiplicatore di Lagrange corrispondente al vincolo di non negatività delle variabili di Slack. Il Lagrangiano è dato da

$$\begin{aligned}\mathcal{L}(w, b, \xi, \alpha, \gamma) &= \frac{1}{2}\|w\|^2 + C \sum_{n=1}^N \xi_n \\ &\quad - \sum_{n=1}^N \alpha_n (y_n (\langle w, x_n \rangle + b) - 1 + \xi_n) - \sum_{n=1}^N \gamma_n \xi_n.\end{aligned}$$

Riduciamo il Lagrangiano derivandolo rispetto alle variabili primali, ossia

$$\begin{aligned}\frac{\partial \mathcal{L}}{\partial w} &= w^\top - \sum_{n=1}^N \alpha_n y_n x_n^\top, \\ \frac{\partial \mathcal{L}}{\partial b} &= - \sum_{n=1}^N \alpha_n y_n, \\ \frac{\partial \mathcal{L}}{\partial \xi_n} &= C - \alpha_n - \gamma_n.\end{aligned}$$

E le imponiamo nulle, in modo da trovare il valore massimo del Lagrangiano. Dalla prime delle tre, otteniamo

$$w = \sum_{n=1}^N \alpha_n y_n x_n$$

osservando che il vettore dei pesi è una combinazione lineare di x_n , ossia degli esempi. Questa è una particolare istanza di **representer theorem**⁶. Sostituiamo w nel Lagrangiano, ottenendo il Duale⁷.

$$\begin{aligned}\mathcal{D}(\xi, \alpha, \gamma) &= \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N y_i y_j \alpha_i \alpha_j \langle x_i, x_j \rangle - \sum_{i=1}^N y_i \alpha_i \left\langle \sum_{j=1}^N y_j \alpha_j x_j, x_i \right\rangle \\ &\quad + C \sum_{i=1}^N \xi_i - b \sum_{i=1}^N y_i \alpha_i + \sum_{i=1}^N \alpha_i - \sum_{i=1}^N \alpha_i \xi_i - \sum_{i=1}^N \gamma_i \xi_i\end{aligned}$$

Dalla seconda derivata delle tre posta a zero, otteniamo che $\sum_{n=1}^N y_n \alpha_n = 0$. Inoltre, possiamo semplificare il termine

$$\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N y_i y_j \alpha_i \alpha_j \langle x_i, x_j \rangle - \sum_{i=1}^N y_i \alpha_i \left\langle \sum_{j=1}^N y_j \alpha_j x_j, x_i \right\rangle \rightarrow -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N y_i y_j \alpha_i \alpha_j \langle x_i, x_j \rangle$$

Otteniamo quindi

⁶Per molti problemi di apprendimento con regolarizzazione, la soluzione ottima può sempre essere scritta come combinazione dei dati di training.

⁷Il problema duale è il problema di ottimizzazione espresso nelle variabili dei moltiplicatori di Lagrange, ottenuto minimizzando la Lagrangiana rispetto alle variabili originali. Per l'SVM, il duale vive sugli α_i , usa solo prodotti scalari tra punti, e ci permette sia di usare i kernel sia di capire chi sono i support vector.

$$\mathcal{D}(\xi, \alpha, \gamma) = -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N y_i y_j \alpha_i \alpha_j \langle x_i, x_j \rangle + \sum_{i=1}^N \alpha_i + \sum_{i=1}^N (C - \alpha_i - \gamma_i) \xi_i.$$

Dalla terza derivata delle tre posta a zero, $C - \alpha_n - \gamma_n = 0$, possiamo annullare l'ultimo termine.

$$\mathcal{D}(\xi, \alpha, \gamma) = -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N y_i y_j \alpha_i \alpha_j \langle x_i, x_j \rangle + \sum_{i=1}^N \alpha_i$$

Ora, massimizzare il problema del duale è equivale a minimizzare il suo negativo. Arriviamo quindi alla formulazione del **Dual SVM**.

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N y_i y_j \alpha_i \alpha_j \langle x_i, x_j \rangle - \sum_{i=1}^N \alpha_i \\ \text{rispetto a} \quad & \sum_{i=1}^N y_i \alpha_i = 0, \\ & 0 \leq \alpha_i \leq C \quad \text{per } i = 1, \dots, N. \end{aligned}$$

$\alpha_i \leq C$ si ottiene da $C = a_n + \gamma_n$, sapendo che γ_n sono non negativi.

Box Constraints Indichiamo con questo nome l'insieme di disuguaglianze $0 \leq \alpha_i \leq C$ per $i = 1, \dots, N$. Questi, limitano il vettore dei moltiplicatori di Lagrange $\alpha = [\alpha_1, \dots, \alpha_N]^\top \in \mathbb{R}^N$ in una "scatola" definita tra 0 e C per ogni asse.

Dal Duale al Primale Una volta trovati i parametri α , possiamo ottenere i parametri w usando il **representer theorem**.

$$w = \sum_{n=1}^N \alpha_n y_n x_n$$

e indicheremo il suo valore ottimale con w^* . Per trovare invece b^* , dobbiamo trovare un punto sul margine, ossia $y_n(\langle w^*, x_n \rangle + b^*) = 1$. Calcoliamo il bias nel seguente modo

$$b^* = y_n - \langle w^*, x_n \rangle$$

9.5 Kernel Trick

La formulazione Dual SVM è molto potente, in quanto permette l'uso di quello che è noto in letteratura come "**kernel trick**". Questo torna utile quando i dati non sono linearmente separabili nello spazio originale.




Figura 9.3: Applicazione di kernel su dati non linearmente separabili. Aumentando di una dimensione, i dati diventano separabili da un iperpiano.

9.5.1 Trasformare i dati

il nostro desiderio, è quello di lavorare nei dati su uno spazio con più dimensioni rispetto all'originale. Una trasformazione esplicita del dataset $x \rightarrow \phi(x)$ in uno spazio più grande, presenta i seguenti rischi:

- Vettori molto lunghi a causa delle troppe features ottenute
- Costi in termini di calcoli e memoria molto alti

9.5.2 Il *Kernel Trick*

Ritorniamo sui nostri passi. La funzione di decisione di un SVM è

$$\min_{\alpha} \quad \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N y_i y_j \alpha_i \alpha_j \langle x_i, x_j \rangle - \sum_{i=1}^N \alpha_i$$

La formulazione in questione, valuta esclusivamente il prodotto scalare delle coppie di campioni $\langle x_i, x_j \rangle$, che ricordiamo essere indice di somiglianza tra i due campioni valutati. Detto ciò, l'idea è quella di **sostituire il prodotto scalare con un kernel**, ossia una funzione $K(x, z)$. Questa, matematicamente, si comporta come un prodotto scalare in uno spazio delle features più grande.

$$K(x, z) = \langle \phi(x), \phi(z) \rangle$$

Possiamo quindi evitare il calcolo esplicito di $\phi(x)$, e lavorare sostituendo il prodotto scalare con il kernel più opportuno.

$$\min_{\alpha} \quad \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N y_i y_j \alpha_i \alpha_j K(x_i, x_j) - \sum_{i=1}^N \alpha_i$$

Ottenendo lo stesso risultato.

Esempio di applicazione con kernel polinomiale di grado 2 Immaginiamo di avere due vettori, $x = (x_1, x_2)$ e $z = (z_1, z_2)$. Supponiamo di mappare $\phi(x)$ e $\phi(z)$, ottenendo

$$\phi(x) = (x_1^2, \sqrt{2}x_1x_2, x_2^2, \sqrt{2}x_1, \sqrt{2}x_2, 1) \quad \phi(z) = (z_1^2, \sqrt{2}z_1z_2, z_2^2, \sqrt{2}z_1, \sqrt{2}z_2, 1)$$

Il prodotto scalare diventa

$$\langle \phi(x), \phi(z) \rangle = x_1^2 z_1^2 + 2x_1 x_2 z_1 z_2 + x_2^2 z_2^2 + 2x_1 z_1 + 2x_2 z_2 + 1$$

Ma lo stesso risultato è ottenibile applicando un kernel polinomiale di grado 2, ossia

$$K(x, z) = (\langle x, z \rangle + 1)^2 = (x_1 z_1 + x_2 z_2 + 1)^2 = x_1^2 z_1^2 + 2x_1 x_2 z_1 z_2 + x_2^2 z_2^2 + 2x_1 z_1 + 2x_2 z_2 + 1$$

Il risultato è il seguente: riusciamo a lavorare su spazi di features molto alti, ma senza mai costruirli.

Riferimenti

Il materiale di questo capitolo è stato tratto da:

- Materiale visto a lezione.
- Parti del capitolo 12 di [2].

Capitolo 10

Ensemble Learning

L'ensemble learning è una tecnica di machine learning che combina le previsioni di più modelli base (detti *base learners* o *weak learners*) per ottenere una previsione complessiva più accurata e robusta. L'idea alla base dell'ensemble learning è che un insieme di modelli, ciascuno con i propri punti di forza e debolezze, possa compensare gli errori reciproci, portando a una migliore performance rispetto a qualsiasi singolo modello.

10.1 Tipi di Ensemble Learning

Per formalizzare il concetto, l'ensemble learning allena L modelli base $h_1(x), h_2(x), \dots, h_L(x)$ su un dataset di addestramento e combina le loro previsioni per ottenere una previsione finale $H(x)$.

10.1.1 Averaging




Figura 10.1: Esempio di ensemble learning tramite averaging: esistono L modelli $H_1, H_2, \dots, H_L$ che fanno previsioni su un dato input x . La previsione finale $H(x)$ è la media delle previsioni dei modelli base.

Un primo metodo di fare ensemble learning è l'**averaging**, che consiste nel calcolare la media delle previsioni dei modelli base. Questo metodo è particolarmente utile per problemi di regressione, dove la previsione finale $H(x)$ è data da:

$$H(x) = \frac{1}{L} \sum_{i=1}^L h_i(x)$$

10.1.2 Weighted Averaging




Figura 10.2: Esempio di ensemble learning tramite weighted averaging: ogni modello H_i ha un peso associato w_i che riflette la sua affidabilità. La previsione finale $H(x)$ è una media pesata delle previsioni dei modelli base.

Un'estensione dell'averaging è il **weighted averaging**, dove ogni modello base ha un peso associato w_i che riflette la sua affidabilità. L'idea è di dare più importanza ai modelli che performano meglio. La previsione finale è calcolata come:

$$H(x) = \frac{\sum_{i=1}^L w_i h_i(x)}{\sum_{i=1}^L w_i}$$

10.1.3 Gating

Un metodo più sofisticato di ensemble learning è il **gating**, in cui un modello di gating $g(x)$ decide quale modello base utilizzare per fare la previsione finale. Questo approccio è particolarmente utile quando i modelli base sono specializzati in diverse regioni dello spazio delle caratteristiche. La previsione finale è data da:

$$H(x) = h_{g(x)}(x)$$

dove $g(x)$ restituisce l'indice del modello base da utilizzare per l'input x .




Figura 10.3: Esempio di ensemble learning tramite gating: un modello di gating $g(x)$ seleziona quale modello base utilizzare per fare la previsione finale $H(x)$.

10.1.4 Stacking

Un altro approccio è lo **stacking**, in cui le previsioni dei modelli base vengono utilizzate come input per un modello di livello superiore (detto *meta-learner*) C allenato su un *validation set*. Questo è utile perché permette al meta-learner di apprendere come combinare le previsioni dei modelli base in modo ottimale. Si può formalizzare come:

$$H(x) = C(h_1(x), h_2(x), \dots, h_L(x))$$




Figura 10.4: Esempio di ensemble learning tramite stacking: le previsioni dei modelli base $H_1, H_2, \dots, H_L$ vengono utilizzate come input per un modello di livello superiore (meta-learner) C che produce la previsione finale $H(x)$.

10.2 Tecniche di Manipolazione dei Dati

Per migliorare la diversità tra i modelli base, l'ensemble learning spesso utilizza tecniche di manipolazione dei dati per creare diversi sottoinsiemi di dati di addestramento. Il vantaggio di questa diversità è che modelli diversi possono catturare differenti aspetti del problema, riducendo il rischio di overfitting e migliorando la generalizzazione.

10.2.1 Bootstrap replication

Una tecnica comune è la **bootstrap replication**, che consiste nel creare diversi sottoinsiemi di dati di addestramento campionando con ripetizione dal dataset originale. Ogni modello base viene addestrato su un sottoinsieme diverso, aumentando la diversità tra i modelli.

Dato un dataset D con n campioni, si creano L sottoinsiemi $D_1, D_2, \dots, D_L$ ciascuno ottenuto campionando n volte con ripetizione da D . Ogni modello base h_i viene quindi addestrato su D_i . Poiché il campionamento è con ripetizione, circa il 36.8% dei campioni originali non verrà incluso in ciascun sottoinsieme, favorendo la diversità tra i modelli.

10.2.2 Bagging

Un'altra tecnica è il **bagging** (bootstrap aggregating), che combina la bootstrap replication con l'averaging. In questo approccio, si creano diversi sottoinsiemi di dati di addestramento tramite bootstrap replication, si addestrano modelli base su ciascun sottoinsieme e si combinano le loro previsioni tramite averaging o weighted averaging. Questo metodo è particolarmente efficace per ridurre la varianza dei modelli base, migliorando la stabilità e la performance complessiva dell'ensemble.

10.2.3 Boosting

Il **boosting** è una tecnica di ensemble learning che mira a creare un forte modello combinando molti modelli deboli in **sequenza**. A differenza del bagging, dove i modelli base sono indipendenti, nel boosting ogni modello successivo viene addestrato per correggere gli errori del modello precedente. Questo processo iterativo porta a un miglioramento continuo delle performance dell'ensemble.

10.3 AdaBoost

Adaboost (Adaptive Boosting) è uno degli algoritmi di boosting più popolari e ampiamente utilizzati. Costruisce un classificatore forte come combinazione pesata di T classificatori deboli (weak hypotheses) h_t , enfatizzando iterativamente gli esempi misclassificati tramite pesi d'istanza $w_{t,i}$.

Input e notazione. Sia il training set $(X, y) = \{(x_i, y_i)\}_{i=1}^n$ e sia T il numero di iterazioni. I pesi al passo t sono $w_t = (w_{t,1}, \dots, w_{t,n})$ e h_t è il modello allenato al passo t .

10.3.1 Algoritmo

Algorithm 1 AdaBoost

Require: Training set $\{(x_i, y_i)\}_{i=1}^n$ with $y_i \in \{-1, +1\}$, number of rounds T

Ensure: Final hypothesis H

```

1: Initialize  $w_{1,i} \leftarrow \frac{1}{n}$  for  $i = 1, \dots, n$ 
2: for  $t = 1, \dots, T$  do
3:   Train weak learner  $h_t$  on  $\{(x_i, y_i)\}_{i=1}^n$  using weights  $w_t$ 
4:    $\varepsilon_t \leftarrow \sum_{i: y_i \neq h_t(x_i)} w_{t,i}$ 
5:    $\alpha_t \leftarrow \frac{1}{2} \ln \left( \frac{1-\varepsilon_t}{\varepsilon_t} \right)$ 
6:   for  $i = 1, \dots, n$  do
7:      $w_{t+1,i} \leftarrow w_{t,i} \exp(-\alpha_t y_i h_t(x_i))$ 
8:   end for
9:   Normalize:  $w_{t+1,i} \leftarrow \frac{w_{t+1,i}}{\sum_{j=1}^n w_{t+1,j}}$  for  $i = 1, \dots, n$ 
10: end for
11: return  $H(x) = \text{sign} \left( \sum_{t=1}^T \alpha_t h_t(x) \right)$ 

```

Si può descrivere cosa fanno i vari passi dell'algoritmo in questo modo:

1. Initialize a vector of n uniform weights

Inizializza una distribuzione uniforme sugli esempi:

$$w_1 = \left[\frac{1}{n}, \dots, \frac{1}{n} \right].$$

Interpretazione: all'inizio tutti gli esempi contano uguale.

2. for $t = 1, \dots, T$

Ciclo di boosting: ad ogni iterazione si costruisce un nuovo weak learner che si concentra sugli esempi più “difficili” (quelli con peso alto).

3. Train model h_t on X, y with instance weights w_t

Allena h_t usando i pesi w_t : gli esempi con $w_{t,i}$ maggiore influenzano di più il training (equivalente a “replicare” più volte quegli esempi).

4. Compute the weighted training error rate of h_t :

$$\varepsilon_t = \sum_{i: y_i \neq h_t(x_i)} w_{t,i}.$$

Interpretazione: è la probabilità (secondo la distribuzione w_t) che h_t sbaglia; non è un errore “non pesato”, ma un errore misurato rispetto ai pesi correnti.

5. Choose $\alpha_t = \frac{1}{2} \ln \left(\frac{1-\varepsilon_t}{\varepsilon_t} \right)$

$$\alpha_t = \frac{1}{2} \ln \left(\frac{1-\varepsilon_t}{\varepsilon_t} \right).$$

Interpretazione: α_t è il peso del weak learner nell'ensemble finale. Se ε_t è piccolo (modello buono), α_t è grande; se $\varepsilon_t \approx 0.5$, $\alpha_t \approx 0$.

6. Update all instance weights:

$$w_{t+1,i} = w_{t,i} \exp(-\alpha_t y_i h_t(x_i)) \quad \forall i = 1, \dots, n.$$

Cosa fa *di preciso*:

- se $y_i = h_t(x_i)$ (predizione corretta), allora $y_i h_t(x_i) = +1$ e $w_{t+1,i} = w_{t,i} e^{-\alpha_t}$: il peso *diminuisce*.
- se $y_i \neq h_t(x_i)$ (predizione errata), allora $y_i h_t(x_i) = -1$ e $w_{t+1,i} = w_{t,i} e^{+\alpha_t}$: il peso *aumenta*.

Quindi i punti sbagliati vengono enfatizzati e i punti corretti “svalutati”.

7. Normalize w_{t+1} to be a distribution:

$$w_{t+1,i} = \frac{w_{t+1,i}}{\sum_{j=1}^n w_{t+1,j}} \quad \forall i = 1, \dots, n.$$

Interpretazione: si riporta la somma dei pesi a 1 così che w_{t+1} resti una distribuzione di probabilità sugli esempi.

8. end for

Dopo T iterazioni si hanno T weak learners e i rispettivi pesi α_t .

9. Return the hypothesis

$$H(x) = \text{sign} \left(\sum_{t=1}^T \alpha_t h_t(x) \right).$$

Interpretazione: è un voto pesato (somma pesata delle predizioni); la $\text{sign}(\cdot)$ restituisce la classe finale.

10.3.2 Decision Boundary

Il decision boundary di un discriminatore è la **frontiera** che separa le diverse classi nello spazio delle caratteristiche. Ovvero quel valore per il classificatore è "indeciso" tra le due classi.

In Adaboost il decision boundary evolve man mano che si aggiungono nuovi weak learners all'ensemble. All'inizio, con pochi weak learners, il decision boundary può essere semplice e lineare. Man mano che si aggiungono più weak learners, il decision boundary diventa più complesso e capace di catturare le caratteristiche non lineari dei dati.

Esempio su dataset two moons. Si può fare un esempio con AdaBoost su un dataset sintetico *two moons* per visualizzare l'evoluzione del decision boundary al crescere del numero di iterazioni. Come weak learner si può usare un *decision stump* (albero di decisione di profondità 1), che fanno una sola divisione lineare.

Nella Figura 10.5 si mostra come il decision boundary di AdaBoost cambia dopo diverse iterazioni (1, 12, 25 e 50). Si può notare che inizialmente il boundary è semplice e lineare,

ma con l'aggiunta di più weak learners diventa sempre più complesso, riuscendo a catturare la forma non lineare del dataset.




Figura 10.5: Evoluzione del decision boundary di AdaBoost al crescere del numero di iterazioni. In alto a sinistra è mostrato il boundary dopo la prima iterazione ($t = 1$), in alto a destra dopo $t = 12$, in basso a sinistra dopo $t = 25$ e in basso a destra il decision boundary finale ($t = 50$). Si osserva come la combinazione sequenziale di weak learners permetta di approssimare progressivamente una frontiera di decisione non lineare, concentrandosi sulle regioni di maggiore difficoltà.

Riferimenti

I riferimenti principali per questo capitolo sono:

- Materiale visto a lezione.
- Materiale sul boosting e AdaBoost dal capitolo 17 del libro *Introduction to Machine Learning* [1].

Parte III

Materiale aggiuntivo

Appendice A

Approfondimenti teorici

A.1 Problema della separabilità non lineare nel perceptrone

Questa parte è tratta dal capitolo 2, dove si parla del perceptrone nella sezione 2.3.

Definizione (separabilità lineare). Sia $X = \{x^{(1)}, \dots, x^{(m)}\} \subset \mathbb{R}^d$ e sia $y \in \{0, 1\}^m$ un insieme di etichette. Diciamo che i due insiemi di punti $A = \{x^{(i)} : y^{(i)} = 1\}$ e $B = \{x^{(i)} : y^{(i)} = 0\}$ sono *linearmente separabili* se esistono $w \in \mathbb{R}^d$ e $b \in \mathbb{R}$ tali che

$$w^\top x > b \quad \forall x \in A, \quad w^\top x < b \quad \forall x \in B.$$

Equivalente: esiste un iperpiano $w^\top x = b$ la cui parte positiva contiene tutti i punti di A e la parte negativa tutti i punti di B .

Quante funzioni booleane sono linearmente separabili? Per m argomenti binari esistono 2^{2^m} funzioni booleane possibili; solo una parte è realizzabile con un singolo classificatore lineare. Dati noti:

$$\begin{aligned} m = 2 &\Rightarrow 14 \text{ su } 16 \text{ sono separabili linearmente,} \\ m = 3 &\Rightarrow 104 \text{ su } 256 \text{ sono separabili linearmente,} \\ m = 4 &\Rightarrow 1882 \text{ su } 65536 \text{ sono separabili linearmente.} \end{aligned}$$

Non esiste una formula chiusa semplice che dia, in funzione di m , quante funzioni sono linearmente separabili; tuttavia si osserva che, all'aumentare di m , la *frazione* di funzioni separabili decresce rapidamente.

Dicotomie di un insieme di punti. Dato $X = \{x^{(1)}, \dots, x^{(m)}\} \subset \mathbb{R}^d$, le possibili etichettature (o *dicotomie*) sono 2^m :

$$\mathcal{Y} = \{0, 1\}^m.$$

Solo una parte di queste dicotomie è realizzabile mediante una frontiera lineare. Con d fissata, il numero di dicotomie realizzabili cresce in modo polinomiale in m (ordine al più

m^d), mentre il totale cresce esponenzialmente (2^m); di conseguenza,

$$\Pr\{\text{dicotomia separabile linearmente}\} \rightarrow 0 \quad \text{quando } m \gg d.$$




Figura A.1: Separabilità non lineare. A sinistra: andamento qualitativo della probabilità che una dicotomia sia linearmente separabile al crescere del numero di campioni m (con dimensione d fissata); a destra: esempio in $\mathbb{R}^2$ di punti non separabili con un singolo iperpiano.

Intuitivamente: se il numero di campioni cresce molto a parità di dimensione d , è sempre meno probabile che una separazione perfetta con una sola retta/iperpiano esista.

A.2 Generalizzazione funzione di costo del softmax

Questa parte è tratta dal capitolo 4 nella sezione 4.9.5.

Il modello softmax è una generalizzazione della regressione logistica multiclasse, si può infatti dimostrare che la funzione di costo del softmax riduce a quella della regressione logistica binaria per $K = 2$ classi. Ricordiamo che la funzione di costo del softmax è:

$$J(\vartheta) = -\frac{1}{m} \sum_{i=1}^m \sum_{c=0}^{K-1} \mathbf{1}\{y^{(i)} = c\} \log(h_{\vartheta}^{(c)}(x^{(i)})) + \frac{\lambda}{2} \sum_{c=0}^{K-1} \sum_{j=1}^n (\vartheta_j^{(c)})^2,$$

È facile vedere che, per $K = 2$ (senza regolarizzazione) vale:

$$\begin{aligned}
 J(\vartheta) &= -\frac{1}{m} \sum_{i=1}^m \sum_{c=0}^1 \mathbf{1}\{y^{(i)} = c\} \log(h_{\vartheta}^{(c)}(x^{(i)})) \\
 &= -\frac{1}{m} \sum_{i=1}^m \left[\mathbf{1}\{y^{(i)} = 0\} \log h_{\vartheta}^{(0)}(x^{(i)}) + \mathbf{1}\{y^{(i)} = 1\} \log h_{\vartheta}^{(1)}(x^{(i)}) \right] \\
 &= -\frac{1}{m} \sum_{i=1}^m \left[(1 - y^{(i)}) \log h_{\vartheta}^{(0)}(x^{(i)}) + y^{(i)} \log h_{\vartheta}^{(1)}(x^{(i)}) \right] \\
 &= -\frac{1}{m} \sum_{i=1}^m \left[(1 - y^{(i)}) \log(1 - h_{\vartheta}^{(1)}(x^{(i)})) + y^{(i)} \log h_{\vartheta}^{(1)}(x^{(i)}) \right],
 \end{aligned}$$

dove si è usata la normalizzazione della softmax $h_{\vartheta}^{(0)}(x) + h_{\vartheta}^{(1)}(x) = 1$. Questa è esattamente la loss della regressione logistica binaria: dunque la regressione logistica è un caso particolare della softmax.

Si può ulteriormente dimostrare che il softmax è una generalizzazione della regressione logistica multiclasse usando una sua proprietà principale: l'*overparametrizzazione*. Per $K = 2$:

$$h_{\vartheta}(x) = \begin{bmatrix} \frac{e^{\vartheta^{(0)\top} x}}{e^{\vartheta^{(0)\top} x} + e^{\vartheta^{(1)\top} x}} \\ \frac{e^{\vartheta^{(1)\top} x}}{e^{\vartheta^{(0)\top} x} + e^{\vartheta^{(1)\top} x}} \end{bmatrix} = \begin{bmatrix} \frac{e^{(\vartheta^{(0)} - \vartheta^{(1)})\top x}}{e^{(\vartheta^{(0)} - \vartheta^{(1)})\top x} + e^{\mathbf{0}^\top x}} \\ \frac{e^{(\vartheta^{(1)} - \vartheta^{(1)})\top x}}{e^{(\vartheta^{(0)} - \vartheta^{(1)})\top x} + e^{\mathbf{0}^\top x}} \end{bmatrix} = \begin{bmatrix} \frac{e^{\Delta^\top x}}{1 + e^{\Delta^\top x}} \\ \frac{1}{1 + e^{\Delta^\top x}} \end{bmatrix}, \quad \Delta = \vartheta^{(0)} - \vartheta^{(1)}.$$

Ponendo $\mathbf{w} = \vartheta^{(1)} - \vartheta^{(0)} = -\Delta$ e $\sigma(z) = \frac{1}{1 + e^{-z}}$ si ottiene

$$h_{\vartheta}(x) = \begin{bmatrix} 1 - \sigma(\mathbf{w}^\top x) \\ \sigma(\mathbf{w}^\top x) \end{bmatrix}.$$

Quindi, per $K = 2$, il softmax riduce alla regressione logistica binaria.

Appendice B

Seminario 1: *Data and AI Law*

Tenuto dal Co-founder e CEO di ICC Digital Media 1999, Giuseppe Fragola, in data 28 Novembre 2025.

B.1 L'importanza dei dati - segreti industriali

Qualsiasi rivoluzione tecnologica ha a che fare con i dati. I dati sono il comune denominatore di ogni settore. I dati non sono da vedersi solo come dati del singolo, ma anche informazioni strategiche e segreti industriali, tra cui:

- Formule
- Progetti
- Fornitori e prezzi
- Organizzazione
- Produzione
- Tecnologie in uso

A tutela dei dati relativi ai segreti industriali, nasce un ampio corpus informativo.

B.1.1 Data Is The New Oil

I dati hanno una valenza strategica enorme. Le organizzazioni criminali, tramite attacchi hacker, puntano a ottenere informazioni preziose per fare speculazione economica. Tra questi dati, ci sono **brevetti, bilanci, fornitori e contratti**. Inoltre, visto l'inevitabile crescita della quantità di dati, i crimini informatici relativi al loro ottenimento illecito, sono destinati ad aumentare nel tempo.

B.1.2 *Mission Genesis* - 25 Novembre 2025

Donald Trump ha recentemente firmato un ordine esecutivo per condividere i dati scientifici di tutte le agenzie governative e utilizzare l'AI (creando un *data lake*¹) per accelerare ricerca, sicurezza nazionale e la razionalizzazione la rete elettrica nazionale.

¹Un data lake è un repository centralizzato che archivia grandi quantità di dati strutturati, semi-strutturati e non strutturati nel loro formato nativo. A differenza di un data warehouse, i dati vengono archiviati senza una struttura predefinita, il che consente una maggiore flessibilità per diverse analisi, tra cui Big Data, machine learning e analisi in tempo reale.

B.1.3 Norme: Data Protection e Copyright

Lavorare con i dati, costringe qualsiasi operatore coinvolto a confrontarsi con le norme relative alla data protection e al diritto d'autore.

B.2 Data Protection

Iniziamo **distinguendo privacy** dalla **data protection**. La privacy è infatti il diritto alla riservatezza nella propria sfera privata da parte di terzi (*Right to be alone*). La data protection fa invece riferimento al **trattamento dei dati personali solo con previa autorizzazione dell'interessato**. I dati possono essere trattati solo col consenso di chi li produce.

Cos'è un dato personale? Una qualsiasi **informazione** che direttamente o indirettamente consente di **identificare una persona fisica**, o le sue abitudini, lo stile di vita, le relazioni personali, lo stato di salute o lo stato economico.

B.2.1 GDPR - La rivoluzione

L'Europa decide di tutelare i propri cittadini, con obiettivo ultimo una bolla di protezione relativa ai dati personali. Nasce il regolamento GDPR. Questo, si applica a:

- Coloro che avendo sede EU trattano dati di soggetti interessati **a prescindere dalla loro nazionalità o residenza**.
- Coloro non EU che per la vendita di beni o servizi, **trattano dati personali** di soggetti interessati **che si trovano in EU**.

Gli spunti sono i seguenti:

- **Privacy by Design**: ogni applicazione che tratta dati degli utenti, deve nascere privacy-oriented, concepito e sviluppato avendo in mente la loro tutela.
- **Privacy by Default**: tutte le opzioni per rispettare la privacy devono essere di default.
- **Consent**
- **Portabilità**
- **Data Breach Notification**, obbligata dopo qualsiasi data breach. La norma non dà degli obblighi di sicurezza, ma sei responsabile di qualsiasi conseguenza.

ma tra i quelli più rivoluzionari, abbiamo anche:

- **Minimizzazione**: ogni azienda deve acquisire il minimo indispensabile dei dati rispetto alla finalità per le quali sono trattati. Registrarsi una newsletter dovrebbe consentire solo all'acquisizione dell'e-mail, non del numero di telefono o altri dati sensibili. Questo implica anche la possibilità, da parte dell'utente, di eliminare account personali su piattaforme online.

- **Informativa e Consenso granulare:** il consenso deve essere rilasciato specificamente per **ciascuna delle finalità di trattamento** dichiarate, **una ad una**.
- **Temporaneità:** i dati devono avere tempo di vita limitato, non possono

Le sanzioni previste arrivano fino al 4% del **fatturato del consolidato mondiale del gruppo**.

B.2.2 Sui Cookies

Conosciamo già i cookies: questi permettono di tracciare informazioni sul browser dell'utente (cookies di sessione e persistenti). Tra questi, abbiamo cookies di prime parti e di terze parti.

- I cookies di prime parti sono generati e leggibili solo dal dominio chi li ha creati
- I cookies di terze parti sono creati da domini esterni a quello che si sta visitando. Questo permette facilmente di tracciare informazioni sulle abitudini di un utente, ottenendo dati (o almeno, del suo browser).

Direttiva del 2009 sui Cookies l'UE introduce la direttiva nota come "Cookies Directive" per regolamentare l'uso dei cookie online. L'obiettivo della norma è quello di **garantire informazione chiara** agli utenti e **regolamentare l'uso dei cookie** attraverso **obbligo di informativa e invio solo previo consenso**.

B.3 Copyright e diritto d'autore

Disambiguiamo i termini.

- Il **copyright** è il diritto di copia. Io che ho creato un contenuto, ho diritto ad una *fee*, un rimborso, ogni qual volta in cui qualcuno me ne richieda una copia. Dura all'incirca 50 anni.
- Il **diritto d'autore** tutela l'autore e la paternità dell'opera, e si acquisisce con la creazione dell'opera stessa. Dura 70 anni dalla morte dell'autore.

B.3.1 Diritto d'autore

Riconosce dei **diritti morali indisponibili**. Tra questi abbiamo che sono **indisponibili**, sono riconosciuti a priori. Si ha il diritto a **paternità, integrità, inedito, pentimento**. I diritti patrimoniali sono invece disponibili, e sono diritto di **riproduzione, diffusione, modifica e traduzione**.

Nonostante la durata fissata sia 70 anni dalla morte dell'autore, esistono delle durate particolari sono quelle di opere a **contributo indistinguibile** e **opere collettive**.

B.3.2 Alla tutela del Software

Dopo anni di incertezza normativa, il software è stato inserito tra le **opere dell'ingegno** tutelate dalla legge sul **diritto d'autore**. La tutela riguarda esclusivamente la forma espressiva originale del software (codice), ma non l'idea, che può essere riprodotta mediante un codice diverso. Allo sviluppatore spettano:

- **Diritti morali** - paternità indisponibile
- **Diritti patrimoniali** - riproduzione, traduzione, adattamento, trasformazione, distribuzione

questi, sono però cedibili (a tempo determinato o indeterminato) mediante opportune licenze d'uso. *Consiglio: non perdere mai le licenze ai software! Tieni sempre una cartella con le licenze.*

B.3.2.1 Comprare il software o una licenza?

Ogni qual volta che "compriamo" un software, in realtà noi stiamo acquistando una licenza (temporanea o non). Comprare un software, in senso stretto, significherebbe acquisirne il sorgente.

B.3.2.2 Principio d'esaurimento

Ogni volta che un bene viene immesso nel mercato, chi lo immette nel mercato non ha più controllo delle eventuali rivendite e della libera circolazione.

B.4 AI e Copyright

Tra i punti più caldi relativi all'intelligenza artificiale e il Copyright, abbiamo:

- AI e creazione di opere nuove.
- AI e creazione di opere derivate.
- AI e i dati d'addestramento.

A chi appartengono i diritti d'autore in questi casi?

B.4.0.1 Parentesi sulle AI generative

L'AI generativa è una categoria di AI che permette la generazione di testi, immagini, video e codice grazie a modelli di machine learning supervisionati, reinforcement learning e LLM addestrati su quantità di dati sempre crescenti. Nel 2022 avviene la prima generazione di contenuti creativi nuovi a partire da un algoritmo. **Le opere generate da AI possono essere tutelate da diritto d'autore?** Se presentano originalità e creatività al pari di quella umana, questa potrebbe essere tutelata.

B.4.1 Posizioni dell'US Copyright Office

- 2023 - Rigetto della richiesta di copuright su un'opera creata da AI. *Non sussiste il necessario nesso tra autore umano ed espressione creativa.*
- 2024 - conferma e chiarimento. *È esclusa ogni tutela per opere create dalla macchina in assenza di una prevalente creatività umana.*
- Nodo aperto: *un nodo abbastanza dettagliato è un apporto creativo prevalentemente umano?*

Il tribunale cinese conferma i diritti riconosciuti all'umano, per gli US la questione rimane aperta.

B.4.2 In Italia

Se prevale l'apporto creativo umano, l'opera resta un'opera dell'ingegno e gode della piena tutela del diritto d'autore e delle categorie IPR tradizionali, attribuite alla persona fisica. ***Trattasi di un opera dell'ingegno solo se prevale la creatività umana.*** Un'enorme area grigia giuridica.

B.4.3 Un primo passo - In Sud Africa

Il Sud Africa cambia la storia riconoscendo il **primo brevetto per una invenzione autonomamente creata da una AI.**

B.4.4 AI e soggettività giuridica

Riconoscere una soggettività giuridica a un'AI risolverebbe problemi di attribuzione del diritto e della responsabilità per danno, ma aprirebbe scenari economici e sociali imprevedibili. Il timore riguarda **AI senzienti e dotate di soggettività**, e il rischio che queste possano diventare **entità potentissime** e ricchissime.

B.4.5 Caso OpenAI

OpenAI attribuisce agli utenti i diritti sulle opere create, riservandosi il diritto di usare l'immagine generata per il training.

B.4.5.1 In assenza di disciplina pattizia

Se l'utente ha fornito un prompt articolato con dati molto specifici e qualificati, l'umano prevale. Altrimenti, il diritto è da attribuirsi agli sviluppatori dell'AI.

B.5 AI e opere derivate

Chi è il responsabile se un'opera realizzata da AI plagia un'opera altrui?

Si rimane in attesa di una nuova proposta normativa. Si è valutato di attribuire la responsabilità agli sviluppatori, ma è ancora una questione aperta (e attualmente sospesa).

B.6 AIG e addestramento

I dataset contengono dati appartenenti a qualcuno: anche qui dovrebbe subentrare il diritto d'autore. Incontriamo una serie di problemi. Tra queste, le pubblicazioni e i contenuti scritti pre-AI generativa non hanno valutato come gestire un arrivo del genere. Le principali criticità legali sono

- **Violazione del diritto d'autore** per i dati usati nel training.
- **I dataset pubblici non forniscono indicazioni sull'uso relativo all'AI.**
- **Opere derivate.** Opere troppo simili potrebbero considerarsi plagio.

Si conclude che, in molti casi, il problema del DDA non è l'AI, ma sono i dataset.

B.6.1 Caso New York Times e OpenAI

New York Times ha fatto causa a OpenAI e Microsoft per violazione del copyright, accusando le aziende di aver utilizzato milioni di suoi articoli per addestrare i loro modelli di intelligenza artificiale senza autorizzazione o compenso. La causa, intentata nel dicembre 2023, è un punto di riferimento globale sul futuro del diritto d'autore nell'era dell'IA generativa.

B.6.2 FIEG contro Google AI

Google AI Overview rappresenta un *Traffic Killer*, ossia una criticità per il fatturato delle testate giornalistiche. FIEG sollecita l'AGCM affinché sensibilizzi la Commissione Europea ad aprire un procedimento ai sensi del **Digital Service ACT**.

B.7 AI Act

È una norma potente che nasce dopo 8 anni di elaborazione, proprio per la complessità della materia. L'obiettivo è stato quello di creare una bolla di AI sicura che garantisca i diritti fondamentali dei cittadini Europei dall'invasione di intelligenze artificiali sviluppate in Cina e negli USA. La norma, purtroppo, nella sua enorme complessità, nasce orfana già dalla sua promulgazione: nei giorni adiacenti alla sua redazione, viene rilasciata la prima AI generativa, creando una norma stroncata, incompleta. Riesce tuttavia a tutelare i cittadini dal profiling invasivo, e a tutelare il diritto d'autore.

B.8 AI Risk Pyramid

Il legislatore è consapevole di non poter creare delle categorie di intelligenze artificiali: definisce quindi una **piramide del rischio**, categorizzando ciascuna AI (attuale e futura) in opportuni livelli di questa piramide, in funzione del rischio che questa rappresenta per l'umanità. Ciascuna di queste categorie, rappresenta degli obblighi molto particolari.



Questa piramide tuttavia è stata soggetta ad un'importante proposta di rinvio.

B.9 L'Italia

L'Italia promulga una propria legge sull'AI, con la scusa di integrare l'AI Act. Copre tutti i settori della nostra economia, introducendo nuovi reati penali, tra cui la **manipolazione del consenso politico tramite IA**, aggrigotaggio e **manipolazione del mercato con IA**, un **aggravante "uso dell'IA"** e la **diffusione di DeepFake**.

B.9.1 "-umano" - Aggiunta all'articolo 1

Viene aggiunta pure la parola "umano" alla fine dell'articolo 1 LDA. Le opere dovranno essere frutto dell'ingegno **umano**.

B.9.2 Reati relativi all'uso dei dati

Introdotti nuovi reati per il:

- Text Data Mining illegittimo o non autorizzato (`robots.txt`).
- Uso dei dataset con opere protette senza base legale.
- Estrazione di contenuti da siti ocn Paywall e TOS.
- Copia di testi, immagini, contenuti protetti "per addestrare modelli AI".
- Aggiramento di opt-out del titolare DDA.
- Riproduzione sostanziale nell'output dell'IA.

B.10 Una soluzione ai problemi

La AI ha esaurito tutti i dati disponibili nel mondo reale, utili per il suo addestramento. Adesso si punta su quelli sintetici.

Appendice C

Seminario 2: *Computer Vision and Medical Imaging*

Dal professore e ricercatore del Dipartimento di Matematica e informatica dell'Università di Cagliari, Andrea Loddo.

C.1 Intelligenza Artificiale

Come siamo arrivati a parlare di intelligenza artificiale al giorno d'oggi? L'intelligenza artificiale non è altro che un termine per trattare degli elementi che fanno capo al Machine Learning. Non è sbagliato dire che **le fondamenta dell'AI sono radicate nel Machine Learning**.

C.1.1 Machine Learning

Non programmare esplicitamente la soluzione ad un problema, ma insegnare ad una macchina delle regole partendo da un insieme di dati che rappresenta il problema.

C.1.2 Machine learning e Deep Learning

Se il Deep Learning è alla base di molte delle soluzioni moderne, perché ha ancora senso parlare di Machine Learning?

Pertinenza del modello rispetto al task. Nel machine learning, le procedure di learning sono più rapide, e operano su meno dati rispetto al DL. I modelli sono più facilmente interpretabili. In un mondo fatto da così tanti task e problemi differenti, *non è opportuno parlare di modelli vecchi, ma piuttosto, di modelli adatti*.

Il machine learning è il punto di partenza. Non dobbiamo dimenticare che il Deep Learning nasce dal Machine Learning, e non può fare a meno dei suoi fondamenti.

C.2 Caso studio 1: radiomica

Per **radiomica** si intende l'**analisi delle immagini mediche** volta a ottenere, tramite opportuni metodi matematici e i calcolatori, **informazioni di tipo quantitativo** da queste **non rilevabili tramite la loro semplice osservazione visiva** da parte dell'operatore. Le informazioni in questione dovranno essere **significative**, in quanto volte ad un supporto allo specialista, come nel caso delle diagnosi clinica.

Perché è rilevante? La radiomica permette di evitare esami molto invasivi, come le **biopsie**, alzando comunque il livello di accuratezza delle diagnosi. Il processo radiomico può essere integrato nel campo medico, al fine di migliorarlo. Dalle immagini è anche possibile ottenere rappresentazioni numeriche di ciò che il radiologo vede, o trovare pattern nascosti ma rilevanti.

Biomarcatori. Definiamo biomarcatore una caratteristica misurabile nell'organismo che fornisce informazioni oggettive sullo stato di salute. Gli output dei nostri modelli dovranno essere fortemente influenzate dai biomarcatori rilevati.

C.2.1 Pipeline radiomica

Acquisire le immagini. Raggi-X, risonanze, ultrasuoni, etc. Queste possono venire da **sorgenti e macchinari differenti**. Questi useranno **protocolli molto differenti**. Bisogna essere anche molto attenti sul cosa si acquisisce, evitando di catturare informazioni non-necessarie o fuorvianti. Insomma, acquisire i dati è uno step molto delicato.

Processing dell'input. Tra cui **resampling** e **quantizzazione**, per ridurre la risoluzione dell'informazione e dei livelli di grigio.

Segmentazione. Da un'immagine che rappresenta un'oggetto, ridurre l'analisi ad una sola parte dell'immagine. Può essere effettuata manualmente, in maniera semi-automatica o del tutto automatica. In alternativa, si possono delineare dei bounding-box, applicando un algoritmo di **object detection**.

Estrazione delle features. Un'immagine è una matrice di numeri. Cosa ce ne facciamo di questi numeri? Bisogna dare una forma sensata, e soprattutto **significativa** a questi numeri. Esistono vari modi di estrarre features. Tra questi: histogram based, texture based, shape based, transform based e deep features extraction.

Analisi delle features e dei campioni. È importante analizzare i campioni, per diagnosticare circostanze di **oversampling** e **undersampling** sulle varie classi. Si possono anche applicare tecniche di **normalizzare** delle features o di **riduzione delle features**, per evitare la *Curse of Dimensionality*¹. In particolar modo, il problema della riduzione

¹La *Curse of Dimensionality* un fenomeno nel machine learning dove le prestazioni e l'efficacia degli algoritmi si deteriorano all'aumentare del numero di variabili (dimensioni) in un dataset, rendendo i dati

delle features non è triviale in alcun modo: ogni tecnica ha infatti pro e contro. Creare features basate su quelle di partenza, crea nuovi dati. Estrarre un sottoinsieme di features, rischia di non rappresentare in maniera opportuno il dominio dei dati.

Costruzione e valutazione del modello. Tramite approcci supervised o unsupervised, e valutare i vari modelli tramite i vari parametri e metriche che è possibile calcolare.

C.2.2 Work 1: feature extraction

Presentiamo alcune conclusioni sulle tecniche usate in alcuni lavori effettuati dal gruppo di ricerca nel campo della radiomica.

Si preferiscono informazioni mirate. Le informazioni puntuali, relative alle zone di interesse, sono più comunicative rispetto alle features che rappresentano l'intera immagine.

Interpretabilità nei modelli. È difficile capire i motivi dietro agli output di alcuni modelli. Nel machine learning, tramite visualizzazioni come la **GradCam**, è possibile mappare in una heatmap le zone d'interesse principali del modello. Nel machine learning, per capire la rilevanza delle features, usiamo metodi come:

- **SHAP** (SHapley Additive exPlanations): questa, permette di capire la rilevanza di ciascuna delle features, e i motivi per cui il modello ha preso determinate decisioni, andando oltre la black-box.
- **Metodo della correlazione:** se due features sono estremamente correlate, ne basta una per dare informazioni pertinenti.

Questi due metodi si occupano quindi di analizzare rispettivamente la correlazione feature-label (desiderata), e la correlazione feature-feature (non desiderata). Queste metodologie permettono di effettuare scelte di feature reduction/selection opportune.

C.2.3 Work 2: Dynamic Feature Selection (DFS)

L'idea è quella di stabilire dinamicamente le features da considerare, in funzione dello stato del modello, del contesto o dell'input ricevuto. Un modello di input, permette di selezionare il peso di ognuna delle features in maniera opportuna. L'utilizzo di questa metodologia ha permesso di ottenere risultati strabilianti sul dataset MNIST, con un'accuracy in testing del 98% con una sola feature. Le performance calano su dataset a risoluzione maggiore e a colori: nonostante ciò, rispetto allo stato dell'arte degli altri algoritmi dinamici, anche un risultato come 0.18 in evaluation è significativo.

C.2.4 Work 3: Federated Feature Selection

Questa tecnica di feature selection si basa su alcune intuizioni che nascono dal **federated learning**.

sparsi e le relazioni difficili da trovare, aumentando esponenzialmente la complessità computazionale e il rischio di overfitting

Federated Learning È una tecnica di machine learning decentralizzata che addestra modelli di IA collaborativi su dati distribuiti, mantenendo le informazioni sensibili sui dispositivi locali senza condividerle. È opportuno al campo medico, in quanto i dati di training non possono essere diffusi.

Federated Feature Selection In questo caso, si contribuisce al modello federato non più con i pesi (che rappresentano come le immagini una forma di informazione sensibile relativa ai pazienti, al contrario di quello che si potrebbe pensare), ma con la rilevanza delle features. Questo permette al modello federato di stabilire il modo con cui i client debbano effettuare la feature selection. I risultati del modello server, valgono per i modelli di tutti i client: considerati due client A, B , questi potrebbero usare dispositivi di acquisizione differenti e modelli molto differenti, ma a parità di tipologia di dati, le features significative sono le stesse.

C.3 Caso studio 2: immagini di cellule del sangue nei vetrini

Ho delle immagini ottenute da dei vetrini, su cui viene ossidato del sangue. Dai vetrini, tiro delle immagini al microscopio. L'immagine può comprendere tre sezioni d'interesse: globuli bianchi, globuli rossi e piastrine. Questo caso studio non è stato approfondito particolarmente a causa dei limiti di tempo, ma è stata offerta una analisi di alcune delle criticità principali, del task, e di alcune soluzioni.

C.4 Machine Learning is not dead.

Delle tecniche, che al giorno d'oggi sono considerate datate e fuorimercato, in realtà ci offrono le fondamenta per le tecniche ritenute moderne, e rimangono comunque viabili. Tutto dipende dal task che si sta affrontando, e da come i dati sono catturati e trattati.

**MACHINE
LEARNING
IS NOT
DEAD**

Bibliografia

- [1] Ethem Alpaydin. *Introduction to Machine Learning*. 3rd. Cambridge, MA: The MIT Press, 2014. ISBN: 9780262028189.
- [2] Marc Peter Deisenroth, A. Aldo Faisal e Cheng Soon Ong. *Mathematics for Machine Learning*. Cambridge University Press, 2020. URL: <https://mml-book.com>.
- [3] Raúl Rojas. *Neural Networks: A Systematic Introduction*. Berlin, Heidelberg: Springer, 1996. ISBN: 978-3540605058.